Révisions L3–M2

Fonctions élémentaires

Calculer ln, exp, sin *et* cos *: séries, réduction d'argument et contrôle du reste*

Fil conducteur. Les séries entières de exp, $\ln(1+x)$, sin et cos convergent bien près de 0 et mal, ou pas du tout, ailleurs. Une machine ne les évalue donc jamais en l'argument qu'on lui donne : elle le *ramène* d'abord dans un petit intervalle autour de 0 grâce à une équation fonctionnelle ($\mathrm{e}^{a+b} = \mathrm{e}^a\mathrm{e}^b$, $\ln(ab) = \ln a + \ln b$, périodicité), y somme un polynôme de degré modeste, puis remonte. Trois erreurs s'ajoutent alors : celle de la troncature de la série, celle des arrondis de chaque opération, et celle qu'introduit la réduction elle-même (une constante comme $\ln 2$ ou π n'est connue qu'approximativement). On les majore une à une, explicitement. Reste la question de l'affichage : savoir que le résultat est à 10^{-p} près ne suffit pas toujours à connaître son arrondi à p chiffres. On termine par ce problème, dit du *fabricant de tables*.

Table des matières

1 Le cadre : ce que « calculer » veut dire **2**

1.1 Erreurs absolue et relative . . . 2

1.2 Le modèle de l'arithmétique flottante . . . 2

1.3 Trois sources d'erreur . . . 5

2 Trois façons de majorer le reste d'une série **5**

2.1 Le reste intégral et l'inégalité de Taylor-Lagrange . . . 5

2.2 Séries alternées . . . 6

2.3 Comparaison à une série géométrique . . . 6

3 Conditionnement d'une somme et schéma de Horner **6**

3.1 Le conditionnement d'une somme . . . 6

3.2 Le schéma de Horner . . . 7

4 L'exponentielle **8**

4.1 La série et son reste . . . 8

4.2 Pourquoi on ne somme pas la série loin de 0 . . . 9

4.3 Réduction d'argument . . . 9

4.4 Seconde réduction : élévations au carré . . . 10

4.5 Le bilan d'erreur complet . . . 10

5 Le logarithme **11**

5.1 La série de $\ln(1+x)$ et son reste exact . . . 11

5.2 La série en argth . . . 12

5.3 Réduction d'argument . . . 12

5.4 Les constantes elles-mêmes . . . 13

6 Sinus et cosinus **14**
6.1 Les séries et leur reste 14
6.2 Réduction modulo $\pi/2$ 14

7 Afficher le bon développement décimal **15**
7.1 Quand une approximation détermine l'arrondi 15
7.2 La stratégie de Ziv 15
7.3 Pourquoi y n'est jamais un point de rupture 16
7.4 Le dilemme du fabricant de tables 16

8 Exercices **17**

1 Le cadre : ce que « calculer » veut dire

1.1 Erreurs absolue et relative

Définition 1.1. Soit $y \in \mathbb{R}$ et $\tilde{y}$ une valeur approchée de y.
— L'**erreur absolue** est $|\tilde{y} - y|$.
— Si $y \neq 0$, l'**erreur relative** est $\dfrac{|\tilde{y} - y|}{|y|}$; de façon équivalente, $\tilde{y} = y(1+\varepsilon)$ avec $|\varepsilon|$ égal à l'erreur relative.

Une calculatrice affiche un nombre fixe de *chiffres significatifs* : c'est donc l'erreur relative qui compte. Une erreur absolue de 10^{-12} est excellente pour $\mathrm{e}^{24} \approx 2{,}6 \cdot 10^{10}$ et catastrophique pour $\mathrm{e}^{-24} \approx 3{,}8 \cdot 10^{-11}$.

1.2 Le modèle de l'arithmétique flottante

Un nombre flottant en base β à p chiffres s'écrit $\pm m \cdot \beta^e$ avec $m = d_0, d_1 \dots d_{p-1}$ (écriture en base β, $d_0 \neq 0$) et e entier dans une plage fixée. Les calculatrices travaillent en base 10 (souvent 13 à 15 chiffres en interne pour 10 affichés) ; les ordinateurs en base 2, la double précision ayant $p = 53$.

Exemple 1.2 (Deux bases, $p = 4$ chiffres)**.** *En base* 10, les flottants s'écrivent $\pm\, d_0, d_1 d_2 d_3 \cdot 10^e$. Le nombre $2026 = 2{,}026 \cdot 10^3$ est représentable. Le nombre $\frac{1}{3} = 0{,}3333\dots$ ne l'est pas ; son arrondi au plus proche est $3{,}333 \cdot 10^{-1}$, avec une erreur absolue de $\frac{1}{3} - 0{,}3333 = \frac{1}{30\,000}$, donc une erreur relative de

$$\frac{1/30\,000}{1/3} = 10^{-4}.$$

Espacement. Rappelons que l'exemple ne retient que $p = 4$ chiffres. Entre 1 et 10, l'exposant vaut $e = 0$ et les flottants à 4 chiffres sont les nombres $d_0, d_1 d_2 d_3$, c'est-à-dire, dans l'ordre,

$$1{,}000;\quad 1{,}001;\quad 1{,}002;\quad \dots;\quad 9{,}998;\quad 9{,}999.$$

Deux flottants consécutifs diffèrent d'une unité sur le dernier chiffre, soit $0{,}001 = 10^{-3}$: entre deux d'entre eux, aucun autre nombre n'est représentable. Entre 10 et 100 ($e = 1$), l'écart passe à 10^{-2}, et ainsi de suite : l'écart absolu grandit avec l'exposant, mais l'écart relatif reste de l'ordre de 10^{-3}.

En base 2, les flottants s'écrivent $\pm\, 1, d_1 d_2 d_3 \cdot 2^e$ (le premier chiffre non nul vaut forcément 1), les d_i valant 0 ou 1. Ainsi $5 = 101_2 = 1{,}010_2 \cdot 2^2$ et $0{,}75 = 0{,}11_2 = 1{,}100_2 \cdot 2^{-1}$ sont représentables. Mais 0,1, dont l'écriture décimale est finie, a une écriture binaire illimitée, et n'est donc pas représentable. Détaillons.

Pourquoi l'écriture binaire de 0,1 *est illimitée.* Un réel $x \in]0,1[$ a une écriture binaire finie si et seulement s'il s'écrit $x = \dfrac{a}{2^n}$ avec a et n entiers. En effet, une écriture finie à n chiffres après la virgule vaut

$$0,c_1c_2\dots c_{n\,2} = \sum_{i=1}^{n} \frac{c_i}{2^i} = \frac{c_1 2^{n-1} + c_2 2^{n-2} + \cdots + c_n}{2^n},$$

et réciproquement, si $0 < a < 2^n$, l'écriture de a en base 2 sur n chiffres donne celle de $a/2^n$. Or, si l'on avait $\frac{1}{10} = \frac{a}{2^n}$, on aurait $2^n = 10a$, donc 5 diviserait 2^n, ce qui est impossible puisque 2 est le seul facteur premier de 2^n. De même, un rationnel a une écriture décimale finie si et seulement s'il s'écrit $a/10^n$: c'est pourquoi $\frac{1}{3}$ n'est représentable dans aucune des deux bases, et $\frac{1}{10}$ seulement en base 10.

Calcul des chiffres. Il s'agit de trouver les chiffres $c_i \in \{0,1\}$ tels que

$$0{,}1 = \frac{c_1}{2} + \frac{c_2}{2^2} + \frac{c_3}{2^3} + \cdots .$$

Première méthode : retirer les puissances de 2. On compare ce qui reste à chaque puissance $\frac{1}{2^i}$: si elle tient dans le reste, $c_i = 1$ et on la retire, sinon $c_i = 0$.

i	1	2	3	4	5	6	7	8	9
$\frac{1}{2^i}$	0,5	0,25	0,125	0,0625	0,03125	0,015625	0,0078125	0,00390625	0,001953125
reste avant	0,1	0,1	0,1	0,1	0,0375	0,00625	0,00625	0,00625	0,00234375
c_i	0	0	0	1	1	0	0	1	1

Cette méthode donne les bons chiffres, mais elle manipule des fractions de plus en plus fines, et l'on ne voit pas que le calcul boucle.

Seconde méthode : doubler. Elle calcule les mêmes c_i, plus simplement. Si $x = \dfrac{c_1}{2} + \dfrac{c_2}{2^2} + \dfrac{c_3}{2^3} + \cdots$, alors

$$2x = c_1 + \Big(\frac{c_2}{2} + \frac{c_3}{2^2} + \cdots\Big).$$

La parenthèse est un nombre de $[0,1[$ (elle ne vaut 1 que si tous les chiffres suivants valent 1, écriture que l'on exclut, comme on exclut $0{,}999\ldots = 1$ en décimal). Donc c_1 est la partie entière de $2x$, et la parenthèse, qui est la partie fractionnaire de $2x$, s'écrit avec les chiffres $c_2, c_3, \ldots$ exactement comme x avec $c_1, c_2, \ldots$ On recommence donc avec elle : on double la partie fractionnaire à chaque étape, et l'on relève la partie entière :

partie fractionnaire	0,1	0,2	0,4	0,8	0,6	0,2	0,4	0,8	0,6	$\cdots$
son double	0,2	0,4	0,8	1,6	1,2	0,4	0,8	1,6	1,2	$\cdots$
chiffre c_i	0	0	0	1	1	0	0	1	1	$\cdots$

La partie fractionnaire 0,2 revient à la sixième étape : le calcul boucle, et le motif 0011 se répète indéfiniment,

$$0{,}1 = 0{,}0001100110011\ldots_2.$$

Mise sous forme flottante. La mantisse doit être dans $[1,2[$. Or $2^{-4} = 0{,}0625 \le 0{,}1 < 0{,}125 = 2^{-3}$, donc l'exposant est $e = -4$ et la mantisse vaut $0{,}1 \times 2^4 = 1{,}6$:

$$0{,}1 = 1{,}6 \cdot 2^{-4} = 1{,}10011001\ldots_2 \cdot 2^{-4}$$

(multiplier par 2^4 décale la virgule de quatre rangs vers la droite).

Arrondi à 4 *chiffres.* Les mantisses représentables $1, d_1d_2d_{3\,2}$ vont de $\frac{1}{8}$ en $\frac{1}{8}$; les deux qui encadrent 1,6 sont $1{,}100_2 = 1{,}5$ et $1{,}101_2 = 1{,}625$. Comme $1{,}6 - 1{,}5 = 0{,}1$ et $1{,}625 - 1{,}6 = 0{,}025$, la plus proche est 1,625, et l'arrondi de 0,1 est

$$1{,}101_2 \cdot 2^{-4} = \frac{1{,}625}{16} = \frac{13}{128} = 0{,}1015625,$$

avec une erreur relative de $\dfrac{0{,}0015625}{0{,}1} \approx 1{,}6\,\%$.

Espacement. Entre 1 et 2 ($e = 0$), les flottants sont $1{,}000_2$, $1{,}001_2$, …, $1{,}111_2$, c'est-à-dire 1, 1,125, 1,25, …, 1,875 : deux flottants consécutifs diffèrent d'une unité sur le dernier chiffre, soit $0{,}001_2 = 2^{-3}$.

Dans les deux bases, l'espacement entre 1 et β vaut β^{1-p} (une unité sur le p-ième chiffre : 10^{-3} et 2^{-3} ici, 2^{-52} en double précision), et l'erreur d'arrondi au plus proche en est au plus la moitié : c'est l'unité d'arrondi u définie ci-dessous ($u = 5 \cdot 10^{-4}$ et $u = \frac{1}{16}$ ici).

Définition 1.3 (Modèle standard)**.** On note $\mathrm{fl}(a \circ b)$ le résultat machine d'une opération $\circ \in \{+, -, \times, /\}$ sur deux flottants. On suppose que chaque opération est **correctement arrondie** (c'est ce qu'impose la norme IEEE 754) : en l'absence de dépassement de capacité,

$$\mathrm{fl}(a \circ b) = (a \circ b)(1 + \delta), \qquad |\delta| \le u, \qquad \text{où } u = \tfrac{1}{2}\,\beta^{1-p}$$

est l'**unité d'arrondi** ($u = 2^{-53} \approx 1{,}1 \cdot 10^{-16}$ en double précision, $u = 5 \cdot 10^{-14}$ pour 14 chiffres décimaux).

Une multiplication par une puissance de la base est *exacte* (seul l'exposant change) : multiplier par 2^k en binaire, par 10^k en décimal, ne coûte aucune erreur. Toute la réduction d'argument repose là-dessus.

Les erreurs relatives d'opérations successives se *multiplient* ; le lemme suivant dit qu'elles s'ajoutent en première approximation, et le quantifie.

Lemme 1.4 (Accumulation des erreurs relatives)**.** Soit $n \ge 1$ tel que $nu < 1$, et posons $\gamma_n = \dfrac{nu}{1 - nu}$. Si $\delta_1, \dots, \delta_n$ vérifient $|\delta_i| \le u$, alors

$$\prod_{i=1}^{n} (1 + \delta_i) = 1 + \theta_n \qquad \text{avec} \qquad |\theta_n| \le \gamma_n.$$

Plus généralement, pour tout réel ε tel que $n|\varepsilon| < 1$,

$$|(1 + \varepsilon)^n - 1| \le \frac{n|\varepsilon|}{1 - n|\varepsilon|}.$$

Démonstration. Posons $P = \prod_{i=1}^{n}(1 + \delta_i)$. Chaque facteur est dans $[1 - u, 1 + u]$, avec $1 - u > 0$, donc $(1 - u)^n \le P \le (1 + u)^n$.

Majoration de $P - 1$. Par l'inégalité $1 + t \le \mathrm{e}^t$, puis $\mathrm{e}^s \le \dfrac{1}{1 - s}$ pour $0 \le s < 1$ (qui équivaut à $1 - s \le \mathrm{e}^{-s}$) :

$$(1 + u)^n \le \mathrm{e}^{nu} \le \frac{1}{1 - nu} = 1 + \frac{nu}{1 - nu} = 1 + \gamma_n.$$

Minoration de $P - 1$. Par l'inégalité de Bernoulli $(1 - u)^n \ge 1 - nu$ (récurrence immédiate : si $(1 - u)^n \ge 1 - nu$, alors $(1 - u)^{n+1} \ge (1 - nu)(1 - u) = 1 - (n + 1)u + nu^2 \ge 1 - (n + 1)u$), donc $P - 1 \ge -nu \ge -\gamma_n$.

Ainsi $|P - 1| \le \gamma_n$. La seconde inégalité est la même preuve, appliquée à n facteurs tous égaux à $1 + \varepsilon$, avec $|\varepsilon|$ au lieu de u. ∎

En pratique, $\gamma_n \approx nu$: n opérations coûtent au plus n unités d'arrondi relatives (par exemple $\gamma_{30} \approx 3{,}3 \cdot 10^{-16}$ en double précision).

1.3 Trois sources d'erreur

Calculer $f(x)$ par une série entière tronquée, évaluée en machine après réduction d'argument, produit une valeur $\tilde{y}$ dont l'écart à $f(x)$ a trois causes, que l'on majore séparément puis que l'on combine :

1. l'**erreur de troncature** (ou de méthode) : on remplace la série par une somme finie ;
2. l'**erreur d'arrondi** : chaque opération de cette somme est arrondie ;
3. l'**erreur sur l'argument réduit** : la réduction fait intervenir une constante ($\ln 2$, $\pi/2$) connue avec une précision finie, et son erreur est multipliée par un entier parfois grand.

2 Trois façons de majorer le reste d'une série

2.1 Le reste intégral et l'inégalité de Taylor-Lagrange

Théorème 2.1 (Formule de Taylor avec reste intégral)**.** Soit I un intervalle, $a, x \in I$, $n \in \mathbb{N}$ et f de classe $\mathcal{C}^{n+1}$ sur I. Alors

$$f(x) = \sum_{k=0}^{n} \frac{f^{(k)}(a)}{k!}(x-a)^k + \int_a^x \frac{(x-t)^n}{n!} f^{(n+1)}(t)\,\mathrm{d}t.$$

Démonstration. Par récurrence sur n. Pour $n = 0$, c'est le théorème fondamental de l'analyse : $f(x) = f(a) + \displaystyle\int_a^x f'(t)\,\mathrm{d}t$. Supposons la formule vraie au rang $n-1$ pour une fonction de classe $\mathcal{C}^{n+1}$ (donc $\mathcal{C}^n$). Une intégration par parties, avec $u(t) = f^{(n)}(t)$ et $v(t) = -\dfrac{(x-t)^n}{n!}$, de sorte que $v'(t) = \dfrac{(x-t)^{n-1}}{(n-1)!}$, donne

$$\begin{aligned}\int_a^x \frac{(x-t)^{n-1}}{(n-1)!} f^{(n)}(t)\,\mathrm{d}t &= \Big[-\frac{(x-t)^n}{n!} f^{(n)}(t)\Big]_a^x + \int_a^x \frac{(x-t)^n}{n!} f^{(n+1)}(t)\,\mathrm{d}t \\ &= \frac{f^{(n)}(a)}{n!}(x-a)^n + \int_a^x \frac{(x-t)^n}{n!} f^{(n+1)}(t)\,\mathrm{d}t,\end{aligned}$$

ce qui, reporté dans la formule au rang $n-1$, donne la formule au rang n. ∎

Corollaire 2.2 (Inégalité de Taylor-Lagrange)**.** Sous les mêmes hypothèses, si $|f^{(n+1)}| \le M$ entre a et x,

$$\Big|f(x) - \sum_{k=0}^{n} \frac{f^{(k)}(a)}{k!}(x-a)^k\Big| \le M\,\frac{|x-a|^{n+1}}{(n+1)!}.$$

Démonstration. On majore l'intégrale :

$$\Big|\int_a^x \frac{(x-t)^n}{n!} f^{(n+1)}(t)\,\mathrm{d}t\Big| \le M\,\Big|\int_a^x \frac{|x-t|^n}{n!}\,\mathrm{d}t\Big| = M\,\frac{|x-a|^{n+1}}{(n+1)!}.$$

∎

C'est l'outil universel, mais il demande une borne M de la dérivée, qui fait souvent intervenir la quantité même qu'on cherche à calculer (pour exp, $M = \mathrm{e}^{|x|}$). Les deux outils suivants s'en passent.

2.2 Séries alternées

Proposition 2.3 (Critère des séries alternées, avec reste)**.** Soit $(b_k)_{k\geq 0}$ une suite de réels positifs, décroissante à partir du rang $n+1$ et de limite nulle. Alors la série $\sum(-1)^k b_k$ converge et son reste $R_n = \sum_{k=n+1}^{+\infty} (-1)^k b_k$ vérifie

$$|R_n| \leq b_{n+1}, \qquad \text{et } R_n \text{ a le signe de } (-1)^{n+1} \text{ (s'il est non nul).}$$

Démonstration. Quitte à multiplier par $(-1)^{n+1}$ et à décaler les indices, il suffit de traiter

$$T = \sum_{j=0}^{+\infty} (-1)^j c_j = c_0 - c_1 + c_2 - \cdots, \qquad c_j = b_{n+1+j},$$

avec (c_j) décroissante de limite nulle, et de montrer $0 \leq T \leq c_0$. Soit $T_m = \sum_{j=0}^{m} (-1)^j c_j$. On a $T_{2m+2} - T_{2m} = c_{2m+2} - c_{2m+1} \leq 0$ et $T_{2m+3} - T_{2m+1} = c_{2m+2} - c_{2m+3} \geq 0$: (T_{2m}) décroît, (T_{2m+1}) croît, et $T_{2m} - T_{2m+1} = c_{2m+1} \to 0$. Les deux suites sont adjacentes, donc convergent vers une même limite T, avec $T_1 \leq T \leq T_0$, soit $c_0 - c_1 \leq T \leq c_0$. Comme $c_0 - c_1 \geq 0$, on obtient $0 \leq T \leq c_0$. ∎

Le reste est donc majoré par le *premier terme négligé*, et l'on connaît même son signe : la somme partielle est alternativement par excès et par défaut, ce qui fournit un encadrement.

2.3 Comparaison à une série géométrique

Proposition 2.4 (Reste d'une série à quotient majoré)**.** Soit (a_k) une suite de réels et $n \in \mathbb{N}$. On suppose qu'il existe $\rho \in [0, 1[$ tel que $|a_{k+1}| \leq \rho\,|a_k|$ pour tout $k \geq n+1$. Alors $\sum a_k$ converge absolument et

$$\Big|\sum_{k=n+1}^{+\infty} a_k\Big| \leq \frac{|a_{n+1}|}{1-\rho}.$$

Démonstration. Une récurrence immédiate donne $|a_{n+1+j}| \leq \rho^j |a_{n+1}|$ pour tout $j \in \mathbb{N}$. Donc

$$\sum_{k=n+1}^{+\infty} |a_k| = \sum_{j=0}^{+\infty} |a_{n+1+j}| \leq |a_{n+1}| \sum_{j=0}^{+\infty} \rho^j = \frac{|a_{n+1}|}{1-\rho},$$

et l'inégalité triangulaire conclut. ∎

Pour une série entière $\sum c_k x^k$, on prend ρ égal au supremum de $|c_{k+1}x/c_k|$ pour $k \geq n+1$: le reste vaut alors « le premier terme négligé, à un facteur $1/(1-\rho)$ près ».

3 Conditionnement d'une somme et schéma de Horner

3.1 Le conditionnement d'une somme

La question. Un calcul en machine ne donne pas la somme exacte des termes qu'on lui confie : chaque opération est arrondie. On verra au paragraphe suivant que, pour une somme de termes, tout se passe *comme si* le calcul était exact, mais portait sur des termes légèrement faussés : chaque terme t_j est remplacé par $t_j(1+\varepsilon_j)$, avec $|\varepsilon_j|$ de l'ordre de quelques unités d'arrondi. La précision du résultat dépend alors d'une seule chose : de combien une somme peut-elle bouger quand on perturbe

ses termes de ε en relatif ? Ce facteur d'amplification est le *conditionnement*. Il dépend des termes, pas de l'algorithme : c'est une propriété du problème.

Définition 3.1. Soit $t_0, \dots, t_N$ des réels de somme $S = t_0 + t_1 + \cdots + t_N$ non nulle. Le **conditionnement** de la somme est

$$\kappa = \frac{|t_0| + |t_1| + \cdots + |t_N|}{|t_0 + t_1 + \cdots + t_N|} \geq 1.$$

L'inégalité $\kappa \geq 1$ est l'inégalité triangulaire. On a $\kappa = 1$ si et seulement si tous les termes non nuls ont le même signe, et κ est grand exactement quand des termes de grande taille se compensent pour donner une somme petite.

Proposition 3.2 (Sensibilité d'une somme)**.** Soit $\varepsilon \geq 0$ et $\varepsilon_0, \dots, \varepsilon_N$ des réels tels que $|\varepsilon_j| \leq \varepsilon$. Posons $\tilde{S} = \sum_{j=0}^{N} t_j(1 + \varepsilon_j)$. Alors

$$\frac{|\tilde{S} - S|}{|S|} \leq \kappa\, \varepsilon,$$

et cette borne est atteinte pour $\varepsilon_j = \varepsilon\, \mathrm{sgn}(t_j)$.

Démonstration. Par différence, puis par l'inégalité triangulaire :

$$|\tilde{S} - S| = \Big|\sum_{j=0}^{N} t_j \varepsilon_j\Big| \leq \sum_{j=0}^{N} |t_j||\varepsilon_j| \leq \varepsilon \sum_{j=0}^{N} |t_j|,$$

et l'on divise par $|S|$. Pour $\varepsilon_j = \varepsilon\, \mathrm{sgn}(t_j)$, on a $t_j \varepsilon_j = \varepsilon |t_j|$ pour tout j, donc les deux inégalités sont des égalités : $|\tilde{S} - S| = \varepsilon \sum_j |t_j|$. ∎

Pourquoi on s'y intéresse. Une erreur relative ε sur les termes devient, au pire, une erreur relative $\kappa\varepsilon$ sur la somme : on perd environ $\log_{10} \kappa$ chiffres significatifs. Et ce pire cas ne se contourne pas par un meilleur algorithme : le simple fait de *stocker* les termes en machine les arrondit à u près, ce qui peut déjà fausser la somme de κu en relatif. Par exemple, avec les deux termes 1 et $-0{,}9999$, on a $S = 10^{-4}$ et $\kappa = 1{,}9999/10^{-4} \approx 2 \cdot 10^4$: une perturbation relative de 10^{-8} des termes peut produire une erreur relative de $2 \cdot 10^{-4}$ sur la somme, soit quatre chiffres perdus. Pour calculer une fonction avec p chiffres exacts, il faut donc s'arranger pour ne sommer que des séries de conditionnement modéré, et c'est l'un des deux rôles de la réduction d'argument (l'autre étant de réduire le nombre de termes).

3.2 Le schéma de Horner

Un polynôme $P(x) = \sum_{j=0}^{N} a_j x^j$, c'est-à-dire $a_0 + a_1 x + \cdots + a_N x^N$, s'évalue par le **schéma de Horner** :

$$b_N = a_N, \qquad b_k = b_{k+1}\, x + a_k \quad (k = N-1, \dots, 0), \qquad P(x) = b_0,$$

soit N multiplications et N additions.

Proposition 3.3 (Erreur d'arrondi du schéma de Horner)**.** On suppose x et les a_j représentables, $2Nu < 1$, et l'on note $\tilde{b}_k$ les valeurs calculées en arithmétique flottante. Alors

$$|\tilde{b}_0 - P(x)| \le \gamma_{2N} \sum_{j=0}^{N} |a_j|\,|x|^j.$$

Si les coefficients ne sont pas représentables (comme $1/k!$) et qu'on utilise leurs arrondis, la même borne vaut avec γ_{2N+1}.

Démonstration. On a $\tilde{b}_N = a_N$ et, pour $k < N$, $\tilde{b}_k = (\tilde{b}_{k+1}\, x\,(1+\delta_k) + a_k)(1+\varepsilon_k)$ avec $|\delta_k|, |\varepsilon_k| \le u$. Montrons par récurrence descendante sur k que

$$\tilde{b}_k = \sum_{j=k}^{N} a_j\, x^{j-k}\,(1+\theta_{j,k}),$$

où $1+\theta_{j,k}$ est un produit d'au plus $2(j-k)+1$ facteurs de la forme $1+\delta$, $|\delta| \le u$, et d'au plus $2(N-k)$ facteurs en tout. Pour $k = N$, c'est vrai avec $\theta_{N,N} = 0$. Si c'est vrai au rang $k+1$, alors

$$\tilde{b}_k = \sum_{j=k+1}^{N} a_j x^{j-k}(1+\theta_{j,k+1})(1+\delta_k)(1+\varepsilon_k) + a_k(1+\varepsilon_k),$$

et chaque terme a gagné au plus deux facteurs : c'est la forme voulue au rang k. Pour $k = 0$, chaque $1+\theta_{j,0}$ est un produit d'au plus $2N$ facteurs, donc $|\theta_{j,0}| \le \gamma_{2N}$ par le lemme 1.4 (on complète par des facteurs égaux à 1). D'où

$$|\tilde{b}_0 - P(x)| = \Big|\sum_{j=0}^{N} a_j x^j \theta_{j,0}\Big| \le \gamma_{2N} \sum_{j=0}^{N} |a_j||x|^j.$$

Remplacer a_j par son arrondi $a_j(1+\eta_j)$, $|\eta_j| \le u$, ajoute un facteur à chaque terme, d'où γ_{2N+1}. ∎

Remarque 3.4 (Ce que dit cette borne)**.** La preuve montre exactement ce qu'annonçait le paragraphe précédent : le résultat calculé $\tilde{b}_0$ est la somme *exacte* des termes $t_j = a_j x^j$ perturbés en $t_j(1+\theta_{j,0})$, avec $|\theta_{j,0}| \le \gamma_{2N}$. La proposition 3.2 donne donc, pour $P(x) \neq 0$,

$$\frac{|\tilde{b}_0 - P(x)|}{|P(x)|} \le \kappa\,\gamma_{2N}, \qquad \kappa = \frac{\sum |a_j||x|^j}{|P(x)|},$$

où κ est le conditionnement de la somme des termes du polynôme (γ_{2N+1} si les coefficients sont arrondis). Quand tous les termes ont le même signe, $\kappa = 1$ et l'erreur relative est au plus quelques unités d'arrondi. Quand les termes alternent et se compensent, κ peut être énorme. Toute la suite consiste à ne sommer que des séries où κ reste de l'ordre de 1.

4 L'exponentielle

4.1 La série et son reste

Pour tout réel r, $\mathrm{e}^r = \sum_{k=0}^{+\infty} \frac{r^k}{k!}$. On note $P_N(r) = \sum_{k=0}^{N} \frac{r^k}{k!}$, soit $1 + r + \frac{r^2}{2!} + \cdots + \frac{r^N}{N!}$.

Proposition 4.1 (Reste de la série exponentielle)**.** Soit $r \in \mathbb{R}$ et $N \in \mathbb{N}$ tels que $|r| < N+2$. Alors

$$|\mathrm{e}^r - P_N(r)| \le \frac{|r|^{N+1}}{(N+1)!} \cdot \frac{1}{1 - \frac{|r|}{N+2}}, \qquad \text{et} \qquad \frac{|\mathrm{e}^r - P_N(r)|}{\mathrm{e}^r} \le \mathrm{e}^{|r|}\, \frac{|r|^{N+1}}{(N+1)!} \cdot \frac{1}{1 - \frac{|r|}{N+2}}.$$

Démonstration. Avec $a_k = r^k/k!$, on a pour tout $k \geq N+1$:

$$\frac{|a_{k+1}|}{|a_k|} = \frac{|r|}{k+1} \leq \frac{|r|}{N+2} = \rho < 1,$$

car $k \geq N+1$ donne $k+1 \geq N+2 > 0$, donc $\frac{1}{k+1} \leq \frac{1}{N+2}$, et $\rho < 1$ par l'hypothèse $|r| < N+2$. La proposition 2.4 donne la première inégalité. La seconde s'en déduit en divisant par $\mathrm{e}^r \geq \mathrm{e}^{-|r|}$. ■

L'inégalité de Taylor-Lagrange donnerait $|\mathrm{e}^r - P_N(r)| \leq \mathrm{e}^{|r|}|r|^{N+1}/(N+1)!$: même ordre de grandeur, mais elle suppose de connaître une borne de $\mathrm{e}^{|r|}$, ce que la comparaison géométrique évite pour l'erreur absolue.

4.2 Pourquoi on ne somme pas la série loin de 0

Trop de termes. Pour $r = 24$, les termes $24^k/k!$ croissent jusqu'à $k = 24$, où ils valent environ $2{,}1 \cdot 10^9$, avant de décroître. Obtenir une erreur relative de 10^{-16} demande, par la proposition 4.1, d'aller jusqu'à $N = 74$.

Une annulation catastrophique pour $r < 0$. Pour $r = -24$, les mêmes termes, de taille 10^9, alternent en signe, alors que leur somme vaut $\mathrm{e}^{-24} \approx 3{,}8 \cdot 10^{-11}$. Le conditionnement de la somme est

$$\kappa = \frac{\sum_k 24^k/k!}{\mathrm{e}^{-24}} \approx \frac{\mathrm{e}^{24}}{\mathrm{e}^{-24}} = \mathrm{e}^{48} \approx 7 \cdot 10^{20},$$

et la proposition 3.3 ne garantit plus aucun chiffre exact. Effectivement, en double précision, la somme de la série pour $r = -24$ donne $1{,}03 \cdot 10^{-7}$ au lieu de $3{,}78 \cdot 10^{-11}$: le résultat est faux de plus de trois ordres de grandeur, alors que chaque opération a été faite avec 16 chiffres. (Pour $r = +24$, tous les termes sont positifs et la même somme est exacte à 10^{-16} près en relatif : seule la lenteur pose problème.)

Application 4.1 — Les arguments négatifs

On pourrait calculer $\mathrm{e}^{-24} = 1/\mathrm{e}^{24}$, et c'est correct : si $\tilde{y} = \mathrm{e}^{24}(1+\varepsilon)$, alors $1/\tilde{y} = \mathrm{e}^{-24}(1+\varepsilon')$ avec $|\varepsilon'| = |\varepsilon|/|1+\varepsilon| \leq |\varepsilon|/(1-|\varepsilon|)$, plus une unité d'arrondi pour la division. Mais la réduction d'argument qui suit traite les deux signes d'un coup.

4.3 Réduction d'argument

Proposition 4.2 (Réduction par $\ln 2$)**.** Pour tout réel x, posons $k = \mathrm{round}(x/\ln 2)$ (l'entier le plus proche) et $r = x - k\ln 2$. Alors

$$\mathrm{e}^x = 2^k\,\mathrm{e}^r, \qquad |r| \leq \frac{\ln 2}{2} \approx 0{,}3466.$$

Démonstration. $\mathrm{e}^x = \mathrm{e}^{k\ln 2 + r} = (\mathrm{e}^{\ln 2})^k \mathrm{e}^r = 2^k \mathrm{e}^r$. Et $|x/\ln 2 - k| \leq \frac{1}{2}$ par définition de l'entier le plus proche ; on multiplie par $\ln 2 > 0$. ■

Le facteur 2^k ne coûte rien en binaire (on ajoute k à l'exposant). Sur $|r| \leq \frac{1}{2}\ln 2$, le conditionnement de la somme est au plus $\mathrm{e}^{2|r|} \leq 2$ et le nombre de termes devient raisonnable : par la proposition 4.1, une erreur relative de troncature inférieure à 10^{-p} demande

précision visée 10^{-p}	10^{-10}	10^{-16}	10^{-34}
$\lvert r\rvert \leq \frac{1}{2}\ln 2$	$N = 9$	$N = 13$	$N = 23$
$\lvert r\rvert \leq \frac{1}{2}\ln 10$	$N = 14$	$N = 19$	—

Une calculatrice décimale réduit plutôt par $\ln 10$: $x = k\ln 10 + r$, $\mathrm{e}^x = 10^k \mathrm{e}^r$, la multiplication par 10^k étant exacte en décimal. L'intervalle est plus large ($|r| \le \frac{1}{2}\ln 10 \approx 1{,}15$), d'où plus de termes, ou une seconde réduction.

4.4 Seconde réduction : élévations au carré

Pour diminuer encore le nombre de termes, on utilise

$$\mathrm{e}^r = \left(\mathrm{e}^s\right)^{2^m}, \qquad s = \frac{r}{2^m},$$

la division par 2^m étant exacte en binaire : on calcule $P_N(s)$ pour $|s| \le 2^{-m-1}\ln 2$, puis on l'élève m fois au carré. Le gain est net (pour 10^{-16}, $N = 7$ si $m = 4$, $N = 4$ si $m = 8$), mais chaque élévation au carré *double* l'erreur relative.

Proposition 4.3 (Propagation par élévations au carré)**.** Si $\tilde z = z(1+\varepsilon)$ avec $2^m|\varepsilon| < 1$, et si les m élévations au carré sont faites exactement, l'erreur relative sur $\tilde z^{\,2^m}$ est au plus $\dfrac{2^m|\varepsilon|}{1-2^m|\varepsilon|}$. Si elles sont faites en arithmétique flottante, il s'y ajoute un facteur $1+\theta$ avec $|\theta| \le \gamma_{2^m-1}$.

Démonstration. $\tilde z^{\,2^m} = z^{2^m}(1+\varepsilon)^{2^m}$ et le lemme 1.4 (seconde forme, avec $n = 2^m$) donne la première affirmation. Pour la seconde, notons $w_0 = \tilde z$ et $w_{i+1} = \mathrm{fl}(w_i^2) = w_i^2(1+\delta_i)$. Une récurrence montre que $w_m = \tilde z^{\,2^m} \displaystyle\prod_{i=0}^{m-1} (1+\delta_i)^{2^{m-1-i}}$: l'arrondi fait à l'étape i est encore élevé $m-1-i$ fois au carré. Le nombre total de facteurs est $\displaystyle\sum_{i=0}^{m-1} 2^{m-1-i} = 2^m - 1$, et le lemme 1.4 conclut. ∎

Application 4.2 — Le prix des élévations au carré

Avec $r = 24 - 35\ln 2 \approx -0{,}2601513$ (réduction de $x = 24$), $m = 8$ et $N = 4$, l'erreur relative de troncature sur e^s, $s = r/256$, vaut $9{,}04 \cdot 10^{-18}$; après les huit élévations au carré (faites exactement), elle vaut $2{,}31 \cdot 10^{-15}$, soit exactement 256 fois plus, comme l'annonce la proposition 4.3. Diviser l'argument par 2^m fait donc perdre m bits : on ne le fait que si l'on dispose de m bits de garde.

4.5 Le bilan d'erreur complet

L'argument réduit est calculé avec une valeur approchée L de $\ln 2$, et l'erreur de L est multipliée par k, qui peut être grand.

Théorème 4.4 (Bilan pour l'exponentielle)**.** Soit $x \in \mathbb{R}$, $k = \mathrm{round}(x/\ln 2)$, $r = x - k\ln 2$, et $\tilde r$ la valeur effectivement calculée, avec $|\tilde r - r| \le \eta$. On suppose $|\tilde r| \le R$, et l'on calcule $\tilde y = 2^k \tilde P$, où $\tilde P$ est la valeur de $P_N(\tilde r)$ obtenue par le schéma de Horner. Alors

$$\left|\frac{\tilde y}{\mathrm{e}^x} - 1\right| \le \alpha + \beta + \alpha\beta,$$

où

$$\alpha = \mathrm{e}^R \frac{R^{N+1}}{(N+1)!} \cdot \frac{1}{1 - \frac{R}{N+2}} + \gamma_{2N+1}\,\mathrm{e}^{2R} \qquad \text{et} \qquad \beta = \mathrm{e}^\eta - 1.$$

Démonstration. On écrit $\dfrac{\tilde y}{\mathrm{e}^x} = \dfrac{2^k\tilde P}{2^k\mathrm{e}^r} = \dfrac{\tilde P}{\mathrm{e}^{\tilde r}} \cdot \mathrm{e}^{\tilde r - r}$, produit de deux facteurs $A = \tilde P/\mathrm{e}^{\tilde r}$ et $B = \mathrm{e}^{\tilde r - r}$.

Facteur A. Par l'inégalité triangulaire, $|\tilde P - \mathrm{e}^{\tilde r}| \le |\tilde P - P_N(\tilde r)| + |P_N(\tilde r) - \mathrm{e}^{\tilde r}|$. Le premier terme est majoré, par la proposition 3.3, par $\gamma_{2N+1}\sum_{k=0}^{N}|\tilde r|^k/k! \le \gamma_{2N+1}\mathrm{e}^{|\tilde r|}$; le second, par la proposition 4.1. On divise par $\mathrm{e}^{\tilde r} \ge \mathrm{e}^{-|\tilde r|}$ et l'on utilise $|\tilde r| \le R$ (les majorants sont croissants en $|\tilde r|$) : $|A-1| \le \alpha$.

Facteur B. Pour tout réel t, $|\mathrm{e}^t - 1| \le \mathrm{e}^{|t|} - 1$ (comparer les séries terme à terme). Comme $|\tilde r - r| \le \eta$, on en déduit $|B-1| \le \mathrm{e}^{\eta} - 1 = \beta$.

Produit. $AB - 1 = (A-1) + (B-1) + (A-1)(B-1)$, d'où $|AB-1| \le \alpha + \beta + \alpha\beta$. Enfin la multiplication par 2^k est exacte. ∎

Le terme $\beta \approx \eta$ est le point délicat. Si $\tilde r = x - kL$ avec $|L - \ln 2| \le \delta$, alors η contient $|k|\,\delta$. Pour x de l'ordre de 700 (la limite de la double précision), k vaut environ 1000 : une constante $\ln 2$ arrondie à u près ferait perdre $\log_2 1000 \approx 10$ bits. On stocke donc $\ln 2$ en *deux morceaux*, $L = L_1 + L_2$, où L_1 n'a que peu de chiffres significatifs, de sorte que kL_1, puis $x - kL_1$, soient calculés exactement ; seul kL_2, petit, introduit une erreur (méthode de Cody et Waite).

Pour aller plus loin

Les bibliothèques modernes remplacent la seconde réduction par une *table* : avec $x = (k + j/2^t)\ln 2 + r$, $0 \le j < 2^t$, on écrit $\mathrm{e}^x = 2^k \cdot 2^{j/2^t} \cdot \mathrm{e}^r$, les 2^t valeurs $2^{j/2^t}$ étant précalculées avec une grande précision. L'intervalle de r est divisé par 2^t sans aucune élévation au carré, donc sans amplification d'erreur (méthode de Tang). Le polynôme utilisé n'est d'ailleurs pas le polynôme de Taylor, mais le polynôme de meilleure approximation uniforme sur l'intervalle de r (algorithme de Remez), de degré un peu plus petit à précision égale.

5 Le logarithme

5.1 La série de $\ln(1+x)$ et son reste exact

Proposition 5.1 (Reste intégral de la série logarithmique)**.** Pour tout $x > -1$ et tout $n \ge 1$,

$$\ln(1+x) = \sum_{k=1}^{n} (-1)^{k+1}\frac{x^k}{k} + R_n(x), \qquad R_n(x) = (-1)^n \int_0^x \frac{t^n}{1+t}\,\mathrm{d}t,$$

où la somme s'écrit aussi $x - \dfrac{x^2}{2} + \cdots + (-1)^{n+1}\dfrac{x^n}{n}$. En conséquence :

(i) si $0 \le x \le 1$, $|R_n(x)| \le \dfrac{x^{n+1}}{n+1}$;

(ii) si $-1 < x < 0$, $|R_n(x)| \le \dfrac{|x|^{n+1}}{(n+1)(1-|x|)}$;

(iii) la série converge vers $\ln(1+x)$ pour $-1 < x \le 1$, et diverge pour $x > 1$.

Démonstration. Pour $t > -1$, la somme géométrique donne $\sum_{k=0}^{n-1}(-t)^k = \dfrac{1-(-t)^n}{1+t}$, donc

$$\frac{1}{1+t} = \sum_{k=0}^{n-1}(-1)^k t^k + (-1)^n \frac{t^n}{1+t}.$$

On intègre de 0 à x : $\displaystyle\int_0^x \frac{\mathrm{d}t}{1+t} = \ln(1+x)$ et $\displaystyle\int_0^x t^k\,\mathrm{d}t = \frac{x^{k+1}}{k+1}$, ce qui donne la formule après le changement d'indice $k+1 \to k$.

(i) Pour $t \in [0,x]$, $0 \le \dfrac{t^n}{1+t} \le t^n$, donc $|R_n(x)| \le \displaystyle\int_0^x t^n \,\mathrm{d}t = \frac{x^{n+1}}{n+1}$.

(ii) Pour $t \in [x,0]$, $1+t \ge 1-|x| > 0$, donc $|R_n(x)| \le \dfrac{1}{1-|x|}\displaystyle\int_x^0 |t|^n \,\mathrm{d}t = \frac{|x|^{n+1}}{(n+1)(1-|x|)}$.

(iii) Dans les deux cas le majorant tend vers 0 quand $n \to +\infty$. Pour $x > 1$, le terme général x^k/k ne tend pas vers 0 : la série diverge grossièrement. ■

Deux leçons. D'abord la série ne sert à rien au-delà de $x = 1$: $\ln z$ pour $z > 2$ est hors d'atteinte. Ensuite, même en $x = 1$, elle est inutilisable : $\ln 2 = 1 - \frac12 + \frac13 - \dots$ avec un reste de l'ordre de $1/(n+1)$ (et la proposition 2.3 ne fait pas mieux), donc 16 chiffres demanderaient de l'ordre de 10^{16} termes.

5.2 La série en argth

Proposition 5.2. Pour tout $y \in]-1,1[$,

$$\ln\frac{1+y}{1-y} = 2\sum_{k=0}^{+\infty}\frac{y^{2k+1}}{2k+1} = 2\Big(y + \frac{y^3}{3} + \frac{y^5}{5} + \cdots\Big),$$

et le reste après les termes d'indices 0 à n vérifie

$$\Big|\ln\frac{1+y}{1-y} - 2\sum_{k=0}^{n}\frac{y^{2k+1}}{2k+1}\Big| \le \frac{2|y|^{2n+3}}{(2n+3)(1-y^2)}.$$

De plus, $y \mapsto \dfrac{1+y}{1-y}$ est une bijection de $]-1,1[$ sur $]0,+\infty[$, de réciproque $z \mapsto \dfrac{z-1}{z+1}$.

Démonstration. Pour $|y| < 1$, les séries de $\ln(1+y)$ et de $\ln(1-y)$ convergent (proposition 5.1, appliquée en y et $-y$, qui sont dans $]-1,1[$). Leur différence est

$$\ln(1+y) - \ln(1-y) = \sum_{k=1}^{+\infty}\frac{(-1)^{k+1}y^k + y^k}{k},$$

où le numérateur vaut $2y^k$ si k est impair et 0 si k est pair : on obtient la série annoncée. Ses termes $a_k = 2y^{2k+1}/(2k+1)$ vérifient, pour $k \ge n+1$, $|a_{k+1}/a_k| = y^2\,\dfrac{2k+1}{2k+3} \le y^2 < 1$, et la proposition 2.4 avec $\rho = y^2$ donne la majoration du reste, de premier terme $|a_{n+1}| = 2|y|^{2n+3}/(2n+3)$. Enfin, pour $z > 0$, l'équation $\frac{1+y}{1-y} = z$ équivaut à $1+y = z - zy$, soit $y = \frac{z-1}{z+1}$, qui est bien dans $]-1,1[$ puisque $|z-1| < z+1$. ■

Pour calculer $\ln z$, on pose donc $y = \dfrac{z-1}{z+1}$ et l'on somme une série en y^2 : chaque terme gagne un facteur y^2, au lieu d'un facteur x pour la série de $\ln(1+x)$. Et la série converge pour *tout* $z > 0$, mais lentement si z est loin de 1 (alors $|y|$ est proche de 1).

5.3 Réduction d'argument

Proposition 5.3 (Réduction par les puissances de 2)**.** Tout réel $z > 0$ s'écrit de façon unique $z = 2^k m$ avec $k \in \mathbb{Z}$ et $m \in [\frac{\sqrt2}{2}, \sqrt2[$. Alors

$$\ln z = k\ln 2 + \ln m, \qquad \ln m = 2\operatorname{argth} y \ \text{ avec } \ y = \frac{m-1}{m+1}, \qquad |y| \le 3 - 2\sqrt2 \approx 0{,}1716.$$

Démonstration. L'existence et l'unicité viennent de ce que les intervalles $2^k\left[\frac{\sqrt{2}}{2}, \sqrt{2}\right[= \left[2^{k-\frac{1}{2}}, 2^{k+\frac{1}{2}}\right[$, $k \in \mathbb{Z}$, forment une partition de $]0, +\infty[$: k est l'entier le plus proche de $\log_2 z$. La fonction $m \mapsto \frac{m-1}{m+1} = 1 - \frac{2}{m+1}$ est croissante ; en $m = \sqrt{2}$ elle vaut $\frac{\sqrt{2}-1}{\sqrt{2}+1} = (\sqrt{2}-1)^2 = 3 - 2\sqrt{2}$, et en $m = \frac{\sqrt{2}}{2}$ elle vaut $\frac{1-\sqrt{2}}{1+\sqrt{2}} = -(3-2\sqrt{2})$. ∎

En binaire, k et m se lisent directement sur l'exposant et la mantisse de z (à un décalage près si la mantisse dépasse $\sqrt{2}$), sans aucune erreur. Comme $y^2 \leq 0{,}0295$, chaque terme de la série apporte environ 1,5 chiffre décimal, et la proposition 5.2 donne le nombre de termes nécessaires (indices 0 à n) pour une erreur absolue inférieure à 10^{-p} sur $\ln m$:

précision visée 10^{-p}	10^{-10}	10^{-16}	10^{-34}
$\lvert y\rvert \leq 3-2\sqrt{2}$	$n = 5$	$n = 9$	$n = 20$

Application 5.1 — La convergence observée

Pour $z = 3504 = 2^{12} \times \frac{219}{256}$, on a $m = \frac{219}{256} = 0{,}85546875$ et $y = \frac{219-256}{219+256} = -\frac{37}{475} \approx -0{,}0779$. Les erreurs des sommes partielles successives, d'indices 0 à n, valent

$$3{,}2 \cdot 10^{-4}, \quad 1{,}2 \cdot 10^{-6}, \quad 5{,}0 \cdot 10^{-9}, \quad 2{,}4 \cdot 10^{-11}, \quad 1{,}2 \cdot 10^{-13}, \quad 6{,}0 \cdot 10^{-16},$$

soit un gain de $\log_{10}(1/y^2) \approx 2{,}2$ chiffres par terme. Pour $n = 5$, la borne de la proposition 5.2 vaut $6{,}02 \cdot 10^{-16}$: elle est presque atteinte, car le rapport des termes successifs est très proche de y^2.

Erreur relative. Pour z proche de 1, $\ln z$ est petit et c'est l'erreur relative qui importe. Elle reste maîtrisée : dans ce cas $k = 0$, $m = z$, et tous les termes de la série en y ont le signe de y, donc la somme est bien conditionnée et $|\ln m| = 2|\operatorname{argth} y| \geq 2|y|$. Encore faut-il que $y = (m-1)/(m+1)$ soit calculé avec une petite erreur *relative*, donc que la soustraction $m - 1$ soit exacte ; elle l'est en arithmétique flottante pour $m \in [\frac{1}{2}, 2]$ (lemme de Sterbenz). En revanche, la formule $\ln(1+x)$ appliquée à $z = 1 + x$, avec $1 + x$ arrondi, perdrait toute précision pour x petit : c'est la raison d'être des fonctions `log1p` et `expm1` des bibliothèques.

Erreur sur $k \ln 2$. Elle est absolue, au plus $|k|\,\delta$ si $\ln 2$ est connu à δ près. Or, pour $k \neq 0$,

$$|\ln z| \geq |k| \ln 2 - \tfrac{1}{2} \ln 2 \geq \tfrac{1}{2}|k| \ln 2,$$

donc l'erreur relative correspondante est au plus $2\delta/\ln 2$: contrairement à l'exponentielle, il n'y a pas d'amplification par k.

5.4 Les constantes elles-mêmes

La réduction utilise $\ln 2$, qu'il faut connaître avec plus de chiffres que la précision de travail. La série en argth y suffit.

- $\ln 2 = 2 \operatorname{argth} \frac{1}{3}$ (car $\frac{1+1/3}{1-1/3} = 2$) : 16 termes pour 10^{-16}.
- $\ln 2 = 2 \operatorname{argth} \frac{1}{5} + 2 \operatorname{argth} \frac{1}{7}$ (car $\frac{1+1/5}{1-1/5} = \frac{3}{2}$, $\frac{1+1/7}{1-1/7} = \frac{4}{3}$ et $\frac{3}{2} \times \frac{4}{3} = 2$) : 11 et 9 termes.
- $\ln 2 = 18 \operatorname{argth} \frac{1}{26} - 2 \operatorname{argth} \frac{1}{4801} + 8 \operatorname{argth} \frac{1}{8749}$, formule « à la Machin » qui sert aux calculs de $\ln 2$ à des millions de décimales.
- $\ln 10 = 3 \ln 2 + 2 \operatorname{argth} \frac{1}{9}$ (car $\frac{1+1/9}{1-1/9} = \frac{5}{4}$ et $10 = 2^3 \times \frac{5}{4}$).

6 Sinus et cosinus

6.1 Les séries et leur reste

Proposition 6.1 (Reste des séries de sin et cos)**.** Pour tout réel x et tout $n \in \mathbb{N}$:

$$\left|\sin x - \sum_{k=0}^{n} (-1)^k \frac{x^{2k+1}}{(2k+1)!}\right| \leq \frac{|x|^{2n+3}}{(2n+3)!}, \qquad \left|\cos x - \sum_{k=0}^{n} (-1)^k \frac{x^{2k}}{(2k)!}\right| \leq \frac{|x|^{2n+2}}{(2n+2)!}.$$

Si de plus $x^2 \leq 6$ (resp. $x^2 \leq 2$), le reste de la série de sin (resp. cos) a le signe du premier terme négligé.

Démonstration. Par Taylor-Lagrange. Toutes les dérivées de sin et cos sont bornées par $M = 1$. Le polynôme de la somme partielle de sin d'indices 0 à n est aussi son polynôme de Taylor d'ordre $2n+2$ en 0 (le coefficient de x^{2n+2} est nul), et le corollaire 2.2 à l'ordre $2n+2$ donne la borne $|x|^{2n+3}/(2n+3)!$. Même raisonnement pour cos, à l'ordre $2n+1$.

Le signe, par les séries alternées. Pour sin, les termes $b_k = |x|^{2k+1}/(2k+1)!$ vérifient, pour tout $k \geq 0$,

$$\frac{b_{k+1}}{b_k} = \frac{x^2}{(2k+2)(2k+3)} \leq \frac{x^2}{6} \leq 1;$$

ils décroissent donc et tendent vers 0, et la proposition 2.3 s'applique. Pour cos, $b_k = x^{2k}/(2k)!$ et

$$\frac{b_{k+1}}{b_k} = \frac{x^2}{(2k+1)(2k+2)} \leq \frac{x^2}{2} \leq 1.$$

■

Sur $|x| \leq \frac{\pi}{4}$, on obtient une erreur absolue inférieure à 10^{-p} avec les termes d'indices 0 à n suivants :

précision visée 10^{-p}	10^{-10}	10^{-16}	10^{-34}
sin, $\lvert x\rvert \leq \frac{\pi}{4}$	$n = 5$	$n = 7$	$n = 14$
cos, $\lvert x\rvert \leq \frac{\pi}{4}$	$n = 6$	$n = 8$	$n = 14$

Pour sin et x petit, c'est l'erreur relative qui compte ; elle est contrôlée car $|\sin x| \geq \frac{2}{\pi}|x|$ sur $[-\frac{\pi}{2}, \frac{\pi}{2}]$ (concavité), de sorte que diviser le reste par $|\sin x|$ ne coûte qu'un facteur $\pi/2$.

6.2 Réduction modulo $\pi/2$

Proposition 6.2. Soit $x \in \mathbb{R}$, $k = \mathrm{round}\left(\frac{x}{\pi/2}\right)$ et $r = x - k\frac{\pi}{2}$, de sorte que $|r| \leq \frac{\pi}{4}$. Alors, selon le reste de k modulo 4 :

$k \bmod 4$	0	1	2	3
$\sin x$	$\sin r$	$\cos r$	$-\sin r$	$-\cos r$
$\cos x$	$\cos r$	$-\sin r$	$-\cos r$	$\sin r$

Démonstration. Par 2π-périodicité, seul k mod 4 compte, et les formules

$$\sin\left(r + \frac{\pi}{2}\right) = \cos r, \qquad \cos\left(r + \frac{\pi}{2}\right) = -\sin r,$$

appliquées une, deux ou trois fois, donnent le tableau. ■

La série brute est ici encore pire que pour exp : en double précision, la somme de la série de sin en $x = 100$ donne environ 10^{26}. Après réduction, $k = 64$, $r = 100 - 32\pi \approx -0{,}530965$, et $\sin 100 = \sin r \approx -0{,}506366$.

Le vrai danger : x grand. L'argument réduit est calculé avec une valeur approchée de $\pi/2$, à δ près ; l'erreur absolue sur r est alors $|k|\,\delta$, et l'erreur relative sur $\sin r$ ou $\cos r$ est de l'ordre de $|k|\,\delta/|r|$ dans le pire cas. Deux effets se cumulent :

— $|k| \approx |x|/(\pi/2)$ est grand : pour $x = 10^{22}$, $k \approx 6{,}4 \cdot 10^{21}$, et obtenir r à 10^{-16} près demande π à environ 10^{-38} près, soit une quarantaine de chiffres ;

— $|r|$ peut être très petit quand x est proche d'un multiple de $\pi/2$, ce qui exige encore des chiffres supplémentaires. Pour les flottants de double précision, le pire cas a été déterminé : il suffit de connaître π avec un nombre fini, mais grand, de bits (de l'ordre du millier pour couvrir toute la plage des exposants).

La méthode de Payne et Hanek ne calcule que les bits de $\frac{2}{\pi}$ utiles à x donné, ce qui rend la réduction exacte pour tout flottant.

7 Afficher le bon développement décimal

On sait désormais garantir $|\tilde{y} - y| \leq \eta$, avec η explicite. La calculatrice affiche l'arrondi de y à p chiffres significatifs. Est-ce le bon ?

7.1 Quand une approximation détermine l'arrondi

Définition 7.1. Soit $\mathcal{F}$ l'ensemble des décimaux strictement positifs à p chiffres significatifs. C'est une partie discrète de $]0, +\infty[$; on numérote ses éléments par ordre croissant, $\cdots < f_{j-1} < f_j < f_{j+1} < \ldots$, et l'on appelle **points de rupture** les milieux $\mu_j = \frac{1}{2}(f_j + f_{j+1})$. L'**arrondi au plus proche** $\mathrm{arr}(y)$ d'un réel $y > 0$ qui n'est pas un point de rupture est l'unique f_j tel que $\mu_{j-1} < y < \mu_j$.

Les points de rupture sont des décimaux, à $p+1$ chiffres significatifs au plus (par exemple, à 3 chiffres, entre $f_j = 1{,}23$ et $f_{j+1} = 1{,}24$, le point de rupture est 1,235).

Proposition 7.2 (Critère d'arrondi)**.** Soit $y > 0$ et $\tilde{y}$ tels que $|\tilde{y} - y| \leq \eta$. Si l'intervalle $[\tilde{y} - \eta, \tilde{y} + \eta]$ est inclus dans $]0, +\infty[$ et ne contient aucun point de rupture, alors $\mathrm{arr}(\tilde{y}) = \mathrm{arr}(y)$.

Démonstration. L'intervalle $J = [\tilde{y} - \eta, \tilde{y} + \eta]$ contient $\tilde{y}$ et y. Les points de rupture forment une suite strictement croissante qui découpe $]0, +\infty[$ en intervalles ouverts $]\mu_{j-1}, \mu_j[$ (plus les points μ_j eux-mêmes) ; J, connexe et sans point de rupture, est inclus dans l'un d'eux, $]\mu_{j-1}, \mu_j[$. Donc $\mathrm{arr}(\tilde{y}) = \mathrm{arr}(y) = f_j$. ∎

La réciproque est fausse, et c'est tout le problème : si l'intervalle $[\tilde{y} - \eta, \tilde{y} + \eta]$ contient un point de rupture, rien ne permet de savoir de quel côté se trouve y, quelle que soit la qualité du calcul. Il faut alors recalculer plus précisément.

7.2 La stratégie de Ziv

Algorithme. On calcule $\tilde{y}_1$ avec une borne η_1 (par exemple $p + 10$ chiffres). Si le critère de la proposition 7.2 est satisfait, on renvoie $\mathrm{arr}(\tilde{y}_1)$. Sinon on recommence avec $\eta_2 < \eta_1$ (par exemple deux fois plus de chiffres), et ainsi de suite.

Théorème 7.3 (Terminaison)**.** Si y n'est pas un point de rupture et si $\eta_i \to 0$, l'algorithme s'arrête.

Démonstration. L'ensemble des points de rupture est fermé et discret, et y n'en fait pas partie : $d = \inf_j |y - \mu_j| > 0$. En effet, les μ_j de $[\frac{y}{2}, \frac{3y}{2}]$ sont en nombre fini (un intervalle compact de $]0, +\infty[$

ne contient qu'un nombre fini de décimaux à p chiffres significatifs), donc à une distance minimale de y strictement positive, et les autres sont à distance au moins $\frac{y}{2}$ de y. Soit i tel que $2\eta_i < d$ et $2\eta_i < y$. Tout point t de $[\tilde{y}_i - \eta_i, \tilde{y}_i + \eta_i]$ vérifie $|t - y| \leq |t - \tilde{y}_i| + |\tilde{y}_i - y| \leq 2\eta_i$, donc $t > 0$ et t n'est pas un point de rupture : le critère est satisfait à l'étape i (au plus tard). ■

7.3 Pourquoi y n'est jamais un point de rupture

Les points de rupture sont rationnels. Il suffit donc de savoir que les valeurs calculées sont irrationnelles, et c'est un théorème profond.

Théorème 7.4 (Lindemann-Weierstrass, admis)**.** Si α est un nombre algébrique non nul (par exemple un rationnel non nul), alors e^{α} est transcendant.

Corollaire 7.5. Soit x un rationnel non nul et $z \neq 1$ un rationnel strictement positif. Alors e^{x}, $\ln z$, $\sin x$ et $\cos x$ sont transcendants, donc irrationnels. En particulier, aucun n'est un point de rupture, et la stratégie de Ziv termine pour tout argument flottant (les flottants sont rationnels), hors des cas triviaux $\mathrm{e}^{0} = 1$, $\ln 1 = 0$, $\sin 0 = 0$, $\cos 0 = 1$ que l'on traite à part.

Démonstration. e^{x} : c'est le théorème avec $\alpha = x$.

$\ln z$: si $\ln z$ était algébrique, il serait non nul (car $z \neq 1$), et le théorème rendrait $z = \mathrm{e}^{\ln z}$ transcendant, alors que z est rationnel.

$\sin x$, $\cos x$: $\mathrm{i}x$ est algébrique non nul, donc $\mathrm{e}^{\mathrm{i}x} = \cos x + \mathrm{i}\sin x$ est transcendant. Si $\sin x$ était algébrique, $\cos x = \pm\sqrt{1 - \sin^2 x}$ le serait aussi (les nombres algébriques forment un corps, stable par racine carrée), donc $\cos x + \mathrm{i}\sin x$ aussi : contradiction. De même pour $\cos x$. ■

7.4 Le dilemme du fabricant de tables

Le théorème 7.3 garantit l'arrêt, mais ne dit pas *quand* : la distance d de y au plus proche point de rupture peut être très petite, et Lindemann ne donne aucune minoration effective. C'est le **dilemme du fabricant de tables** (*table maker's dilemma*) : pour garantir l'arrondi correct de toute une table, combien de chiffres faut-il calculer ?

Une heuristique. Supposons les chiffres de y au-delà du p-ième « aléatoires ». La probabilité que y soit à moins de 10^{-m} (en unités du dernier chiffre affiché) d'un point de rupture est alors de l'ordre de 10^{-m}. Sur une table de T arguments, on s'attend donc à rencontrer un pire cas avec $m \approx \log_{10} T$ chiffres supplémentaires. Pour la double précision (T de l'ordre de 2^{53} arguments par intervalle d'exposant, sur quelques milliers d'exposants), cela suggère de travailler avec environ $2p$ bits, et non $p+$ « quelques bits ».

Pour aller plus loin

Lefèvre et Muller ont déterminé, par une recherche exhaustive des pires cas, la précision intermédiaire qui suffit pour arrondir correctement exp, ln, sin, cos et d'autres fonctions sur *tous* les flottants de double précision ; les résultats sont conformes à l'heuristique ci-dessus. C'est ce qui permet aux bibliothèques à arrondi correct (comme CRlibm, puis CORE-MATH) de borner le nombre d'itérations de la stratégie de Ziv, et à la norme IEEE 754-2008 de *recommander* l'arrondi correct de ces fonctions.
Une calculatrice ne va généralement pas jusque-là : elle calcule avec quelques chiffres de garde (par exemple 13 ou 15 chiffres internes pour 10 affichés). Son affichage est donc juste sauf si y tombe à moins de 10^{-g} près d'un point de rupture, g étant le nombre de chiffres de garde, ce qui n'arrive, d'après l'heuristique, que pour une proportion de l'ordre de 10^{-g} des arguments.

8 Exercices

Exercice 1 (Le nombre e)**.** Combien de termes de la série $\sum 1/k!$ faut-il sommer pour obtenir e à 10^{-10} près ?

Correction. Par la proposition 4.1 en $r = 1$, le reste après $P_N(1)$ est au plus $\dfrac{1}{(N+1)!} \cdot \dfrac{N+2}{N+1}$. Pour $N = 12$ cette borne vaut environ $1{,}7 \cdot 10^{-10}$, trop grand ; pour $N = 13$, environ $1{,}2 \cdot 10^{-11}$. Il faut donc $N = 13$, soit 14 termes ($k = 0$ à 13).

Exercice 2 (Deux formules pour $\ln 2$)**.**

1. Vérifier que $\ln 2 = 2\operatorname{argth}\frac{1}{3} = 2\operatorname{argth}\frac{1}{5} + 2\operatorname{argth}\frac{1}{7}$.
2. À l'aide de la proposition 5.2, comparer le nombre de termes nécessaires pour obtenir $\ln 2$ à 10^{-16} près dans les deux cas.

Correction. 1. Pour $y = \frac{1}{3}$, $\frac{1+y}{1-y} = \frac{4/3}{2/3} = 2$. Pour $y = \frac{1}{5}$ et $y = \frac{1}{7}$, on obtient $\frac{3}{2}$ et $\frac{4}{3}$, de produit 2, et ln transforme le produit en somme.

2. Pour $y = \frac{1}{3}$, il faut le plus petit n tel que $\frac{2 \cdot 3^{-(2n+3)}}{(2n+3)(8/9)} \leq 10^{-16}$, soit $n = 15$: 16 termes. Pour $y = \frac{1}{5}$ et $y = \frac{1}{7}$, on répartit l'erreur ($5 \cdot 10^{-17}$ chacune) et l'on trouve $n = 10$ et $n = 8$, soit $11 + 9 = 20$ termes. Le gain n'est pas dans le nombre total de termes, mais dans leur coût : un terme de la série en $\frac{1}{7}$ s'obtient du précédent en divisant par 49, et la convergence plus rapide se paie surtout quand on vise des milliers de chiffres, où les formules à petits arguments ($\frac{1}{26}$, $\frac{1}{4801}$, $\frac{1}{8749}$) l'emportent nettement.

Exercice 3 (Bilan pour exp en double précision)**.** On prend $u = 2^{-53}$, $R = \frac{1}{2}\ln 2$ et $N = 13$ dans le théorème 4.4.

1. Majorer α.
2. On suppose $\eta \leq 2^{-60}$ (réduction de Cody et Waite). Majorer l'erreur relative finale. Combien de bits de la double précision sont garantis ?

Correction. 1. La troncature vaut au plus $\mathrm{e}^R \frac{R^{14}}{14!} \cdot \frac{1}{1-R/15} \approx 6{,}0 \cdot 10^{-18}$ (c'est le choix de $N = 13$ du tableau). L'arrondi vaut au plus $\gamma_{27}\,\mathrm{e}^{2R} = 2\gamma_{27} \approx 2 \times 27 \times 1{,}11 \cdot 10^{-16} \approx 6{,}0 \cdot 10^{-15}$. Donc $\alpha \leq 6{,}1 \cdot 10^{-15}$.

2. $\beta = \mathrm{e}^{\eta} - 1 \leq 2^{-60}(1 + 2^{-60}) \approx 8{,}7 \cdot 10^{-19}$, négligeable. L'erreur relative est donc au plus $6{,}1 \cdot 10^{-15}$, soit environ $55\,u$: on perd $\log_2 55 \approx 6$ bits, il en reste 47 sur 53. La borne de la proposition 3.3 est pessimiste (les erreurs d'arrondi se compensent en partie), mais pour *garantir* les 53 bits on calcule en interne avec une précision supérieure (arithmétique « double-double », ou chiffres de garde sur une calculatrice), et l'on conclut par la proposition 7.2.

Exercice 4 (Duplication du cosinus)**.** On calcule $\cos x$ pour x petit en calculant $c = \cos(x/2)$, puis $\cos x = 2c^2 - 1$. Montrer que si $\tilde{c} = c(1+\varepsilon)$, l'erreur *absolue* sur $2\tilde{c}^2 - 1$ est d'environ $4|\varepsilon|$, et expliquer pourquoi la formule $\cos x = 1 - 2\sin^2(x/2)$ est préférable.

Correction. $2\tilde{c}^2 - 1 = 2c^2(1+\varepsilon)^2 - 1 = (2c^2 - 1) + 2c^2(2\varepsilon + \varepsilon^2)$, et $c^2 \approx 1$ pour x petit : l'erreur absolue vaut environ $4|\varepsilon|$. Comme $\cos x \approx 1$, l'erreur relative est du même ordre : rien de grave pour $\cos x$ lui-même. Mais si l'on s'intéresse à $1 - \cos x \approx x^2/2$, très petit, l'erreur relative sur cette quantité explose. Avec $s = \sin(x/2)$ calculé à ε près en relatif, $2s^2$ est connu à $2|\varepsilon|$ près en *relatif* : la formule $1 - \cos x = 2\sin^2(x/2)$ évite la soustraction de deux nombres voisins de 1. C'est le même phénomène que pour `expm1` et `log1p`.

Références

— J.-M. Muller, *Elementary Functions : Algorithms and Implementation*, Birkhäuser, 3e éd., 2016 (la référence sur le sujet : réduction d'argument, Cody-Waite, Payne-Hanek, Tang, dilemme du fabricant de tables).

— N. J. Higham, *Accuracy and Stability of Numerical Algorithms*, SIAM, 2e éd., 2002 (modèle standard, constantes γ_n, schéma de Horner).

— J.-M. Muller et al., *Handbook of Floating-Point Arithmetic*, Birkhäuser, 2e éd., 2018.

— W. J. Cody, W. Waite, *Software Manual for the Elementary Functions*, Prentice-Hall, 1980.

— A. Ziv, « Fast evaluation of elementary mathematical functions with correctly rounded last bit », *ACM Transactions on Mathematical Software* 17(3), 1991.

— M. Payne, R. Hanek, « Radian reduction for trigonometric functions », *SIGNUM Newsletter* 18, 1983.

— V. Lefèvre, J.-M. Muller, « Worst cases for correct rounding of the elementary functions in double precision », *15th IEEE Symposium on Computer Arithmetic*, 2001.