Révisions L3–M2

Le théorème central limite

Pourquoi un sondage de 1 000 personnes suffit, et d'où viennent les racines carrées des incertitudes

---

Fil conducteur. Un institut interroge 1 000 personnes et annonce : « 52 % des Français approuvent, avec une marge d'erreur de 3 points ». Trois questions se posent. Pourquoi 3 points ? Pourquoi la marge ne dépend-elle pas de la taille de la population (49 millions d'électeurs) ? Et pourquoi faut-il quatre fois plus de personnes pour diviser la marge par deux ? Le physicien rencontre les mêmes questions sous un autre nom : il mesure dix fois une durée, divise l'écart-type par $\sqrt{10}$, et combine les incertitudes de plusieurs grandeurs par des « sommes quadratiques » $\sqrt{u_1^2 + u_2^2}$, souvent sans qu'on lui dise pourquoi.
Tout repose sur deux faits. Le premier est élémentaire : la variance d'une somme de variables indépendantes est la somme des variances, donc l'écart-type d'une moyenne de n mesures est $\sigma/\sqrt{n}$. *C'est l'origine de toutes les racines carrées.* Le second est profond : la somme d'un grand nombre de petites contributions indépendantes suit approximativement une *loi normale*, quelle que soit la loi de chaque contribution. C'est le *théorème central limite* (TCL). Le premier fait donne l'*ordre de grandeur* des erreurs, le second donne leur *forme*, et donc les probabilités : « 95 % de chances d'être à moins de deux écarts-types ».
On démontre le TCL par la méthode de Lindeberg (1922) : on remplace les variables, une à une, par des variables normales, et l'on contrôle chaque remplacement par une formule de Taylor. La preuve n'utilise ni fonction caractéristique ni théorème de Lévy ; elle explique en plus *pourquoi* la loi normale apparaît : c'est la seule loi qui ne change pas quand on ajoute des copies indépendantes d'elle-même et qu'on renormalise.

Table des matières

Ce que l'on suppose connu **2**

Partie A — Le problème : l'erreur d'une moyenne **3**

1 Le modèle du sondage, et la loi en $\sqrt{n}$ **3**

1.1 Le modèle 3

1.2 Mesurer une dispersion : pourquoi la variance ? 3

1.3 Variance d'une somme : l'origine des racines carrées 6

1.4 Une première marge, par Bienaymé-Tchebychev 7

2 Ce que l'on observe : la forme en cloche **7**

Partie B — La loi normale **8**

3 L'intégrale de Gauss et la loi normale **8**

Partie C — Le théorème central limite et sa preuve **10**

4 Convergence en loi, et comment la démontrer **10**

5 Le théorème de Lindeberg **11**
5.1 Le cas de variables de même loi 13

6 Deux outils pour les applications : Slutsky et la méthode delta **14**

Partie D — Les sondages, et au-delà **16**

7 La marge d'erreur d'un sondage **16**
7.1 Pourquoi la taille de la population n'intervient pas 17

8 Au-delà des sondages **17**

Partie E — Les incertitudes en physique-chimie **18**

9 Le modèle d'une mesure **18**

10 L'incertitude d'une moyenne : d'où vient $s/\sqrt{n}$ **18**
10.1 L'incertitude d'une seule lecture : d'où vient $a/\sqrt{3}$ 20

11 La propagation des incertitudes : d'où viennent les sommes quadratiques **20**
11.1 Le cas linéaire : un calcul exact 20
11.2 Le cas général : linéariser, puis appliquer le TCL 21

12 Les comptages : d'où vient $\sqrt{N}$ **22**

13 Ce que le TCL ne dit pas **23**

14 Synthèse **23**

15 Exercices **23**

Références **25**

Ce que l'on suppose connu

Les variables aléatoires sont définies sur un espace probabilisé $(\Omega, \mathcal{A}, \mathbb{P})$. On utilise : la linéarité et la croissance de l'espérance ; le fait que, si X et Y sont indépendantes, $f(X)$ et $g(Y)$ le sont, et $\mathbb{E}[f(X)g(Y)] = \mathbb{E}[f(X)]\,\mathbb{E}[g(Y)]$ dès que ces espérances existent ; le calcul de l'espérance d'une variable à densité $\mathbb{E}[h(X)] = \int h(x) f_X(x)\,\mathrm{d}x$; le théorème de Fubini-Tonelli pour les fonctions positives et la formule de densité d'une somme de deux variables indépendantes à densité ; l'existence, quitte à agrandir l'espace probabilisé, de variables normales indépendantes entre elles et des variables déjà données ; la formule de Taylor-Lagrange ; l'inégalité de Hölder $\mathbb{E}[|UV|] \leq \mathbb{E}[|U|^p]^{1/p}\,\mathbb{E}[|V|^q]^{1/q}$ pour $\frac{1}{p} + \frac{1}{q} = 1$. Tous les autres énoncés sont démontrés.

Partie A — Le problème : l'erreur d'une moyenne

1 Le modèle du sondage, et la loi en $\sqrt{n}$

1.1 Le modèle

Une population compte une proportion inconnue $p \in]0,1[$ de personnes qui répondent « oui ». On interroge n personnes tirées au hasard, de façon indépendante (on discutera ce point à la section 7.1), et l'on note $X_i = 1$ si la i-ème répond « oui », $X_i = 0$ sinon. Les X_i sont indépendantes, de loi de Bernoulli de paramètre p. La proportion observée est

$$\widehat{p}_n = \frac{X_1 + X_2 + \cdots + X_n}{n} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

C'est une variable aléatoire : un autre échantillon donnerait une autre valeur. La question « quelle est la marge d'erreur ? » signifie : *à quelle distance de p la variable $\widehat{p}_n$ tombe-t-elle, avec une probabilité donnée ?*

Le même schéma décrit une mesure physique répétée : X_i est le résultat de la i-ème mesure d'une grandeur, et l'on estime sa valeur par la moyenne $\overline{X}_n = \dfrac{1}{n}\displaystyle\sum_{i=1}^{n} X_i$. On travaille donc dans le cadre général suivant.

Cadre. $X_1, X_2, \ldots$ sont des variables aléatoires réelles indépendantes, de même loi, d'espérance μ et de variance $\sigma^2 > 0$ finie. On note $S_n = X_1 + \cdots + X_n$ et $\overline{X}_n = S_n/n$.

1.2 Mesurer une dispersion : pourquoi la variance ?

Avant de calculer, une objection s'impose. L'écart-type $\sigma = \sqrt{\mathbb{E}[(X-\mu)^2]}$ est défini par un carré et une racine carrée ; on ne s'étonnera donc pas de voir des racines carrées dans la suite. Mais pourquoi mesurer la dispersion ainsi ? L'indicateur le plus naturel *a priori* est l'écart absolu moyen, que l'on définit ainsi.

Définition 1.1 (écart absolu moyen)**.** Soit X une variable aléatoire réelle admettant une espérance, et $\mu = \mathbb{E}[X]$. On appelle **écart absolu moyen** de X, et l'on note $\delta(X)$, le réel

$$\delta(X) = \mathbb{E}\big[|X - \mu|\big].$$

C'est la distance moyenne entre X et sa moyenne, sans carré ni racine. Il a l'unité de X, comme l'écart-type $\sigma(X) = \sqrt{\mathbb{E}[(X-\mu)^2]}$.

Si les racines carrées de la physique n'étaient qu'un effet de la définition de σ, elles disparaîtraient avec δ. Ce n'est pas le cas, et la raison du choix de σ est ailleurs. Quatre faits la donnent.

1. La variance s'ajoute, l'écart absolu moyen non

On démontre plus bas (proposition 1.4) que, pour des variables indépendantes,

$$\mathbb{V}(X+Y) = \mathbb{V}(X) + \mathbb{V}(Y),$$

exactement et quelles que soient les lois. Rien de tel pour δ : il n'existe *aucune* formule donnant $\delta(X+Y)$ à partir de $\delta(X)$ et $\delta(Y)$. En voici la preuve par un exemple.

Exemple 1.2. Soit X et Y deux variables indépendantes, uniformes sur $\{-1,1\}$ (une pièce qui donne ± 1). Alors $\delta(X) = \delta(Y) = 1$, et $X+Y$ vaut -2, 0, 2 avec les probabilités $\frac{1}{4}$, $\frac{1}{2}$, $\frac{1}{4}$, donc $\delta(X+Y) = 1$.

Soit maintenant X' et Y' deux variables indépendantes, de même loi

$$\mathbb{P}(X'=3) = \mathbb{P}(X'=-3) = \frac{1}{6}, \qquad \mathbb{P}(X'=0) = \frac{2}{3}.$$

Encore $\delta(X') = \delta(Y') = 3 \cdot \frac{1}{3} = 1$. Mais $X'+Y'$ vaut ± 6 avec probabilité $\frac{1}{36}$, ± 3 avec probabilité $2 \cdot \frac{1}{6} \cdot \frac{2}{3} = \frac{2}{9}$, et 0 sinon, d'où

$$\delta(X'+Y') = 2\Big(6 \cdot \frac{1}{36} + 3 \cdot \frac{2}{9}\Big) = \frac{5}{3} \neq 1.$$

Mêmes écarts absolus moyens au départ, écarts différents pour la somme : δ de la somme dépend de toute la loi, pas seulement des δ. La variance, elle, se calcule : $\mathbb{V}(X) = 1$, $\mathbb{V}(X') = 9 \cdot \frac{1}{3} = 3$, et $\mathbb{V}(X+Y) = 2$, $\mathbb{V}(X'+Y') = 6$.

Pour étudier une somme d'erreurs, il faut un indicateur qui se combine par une règle simple. La variance est le seul indicateur usuel qui ait cette propriété : c'est la raison première de son choix.

2. La croissance en $\sqrt{n}$ ne vient pas de la définition

Le phénomène fondamental est que la variance d'une somme de n erreurs indépendantes croît *linéairement*, comme $n\sigma^2$. La racine carrée n'apparaît qu'en revenant à l'unité de X (l'écart-type a l'unité de X, la variance son carré). Et la croissance en $\sqrt{n}$ est intrinsèque : avec l'écart absolu moyen, on la retrouve.

Proposition 1.3 (l'écart absolu moyen d'une somme croît aussi en $\sqrt{n}$)**.** Soit $Y_1, \dots, Y_n$ indépendantes, de même loi, centrées, de variance $\sigma^2 > 0$ et de moment d'ordre 4 fini $m_4 = \mathbb{E}[Y_1^4]$. Posons $S_n = Y_1 + \cdots + Y_n$. Alors

$$c\sqrt{n} \leq \mathbb{E}\big[|S_n|\big] \leq \sigma\sqrt{n}, \qquad \text{avec} \qquad c = \frac{\sigma^3}{\sqrt{m_4 + 3\sigma^4}} > 0.$$

Démonstration. Majoration. Par Cauchy-Schwarz, $\mathbb{E}[|S_n|] \leq \sqrt{\mathbb{E}[S_n^2]}$. Or, pour $i \neq j$, l'indépendance donne $\mathbb{E}[Y_iY_j] = \mathbb{E}[Y_i]\,\mathbb{E}[Y_j] = 0$, donc

$$\mathbb{E}[S_n^2] = \sum_{i,j} \mathbb{E}[Y_iY_j] = \sum_i \mathbb{E}[Y_i^2] = n\sigma^2, \qquad \text{et} \qquad \mathbb{E}\big[|S_n|\big] \leq \sigma\sqrt{n}.$$

Le moment d'ordre 4. En développant $S_n^4 = \sum_{i,j,k,l} Y_iY_jY_kY_l$, tout terme où un indice apparaît une seule fois est d'espérance nulle (on factorise l'espérance de ce Y_i isolé, qui est nulle). Restent les termes Y_i^4 (n termes) et les termes $Y_i^2Y_j^2$ avec $i \neq j$ ($3n(n-1)$ termes : choisir les deux indices et la façon de les apparier). Donc

$$\mathbb{E}[S_n^4] = n\,m_4 + 3n(n-1)\,\sigma^4 \leq n^2\,(m_4 + 3\sigma^4).$$

Minoration. On écrit $S_n^2 = |S_n|^{2/3} \cdot |S_n|^{4/3}$ et l'on applique Hölder avec les exposants $p = \frac{3}{2}$ et $q = 3$:

$$n\sigma^2 = \mathbb{E}[S_n^2] \leq \mathbb{E}\big[|S_n|\big]^{2/3}\,\mathbb{E}[S_n^4]^{1/3}, \qquad \text{donc} \qquad \mathbb{E}\big[|S_n|\big] \geq \frac{(n\sigma^2)^{3/2}}{\mathbb{E}[S_n^4]^{1/2}} \geq \frac{n^{3/2}\sigma^3}{n\sqrt{m_4+3\sigma^4}} = c\sqrt{n}.$$

■

Avec la pièce de l'exemple 1.2, on trouve exactement $\mathbb{E}[|S_n|] = 1,\ 1,\ \frac{3}{2},\ \frac{3}{2},\ \frac{15}{8}$ pour $n = 1, \dots, 5$: ni additif ni linéaire, mais bien de l'ordre de $\sqrt{n}$. Quel que soit l'indicateur raisonnable choisi (écart-type, écart absolu moyen, écart interquartile…), la taille typique d'une somme de n erreurs indépendantes est de l'ordre de $\sqrt{n}$ fois celle d'une erreur : c'est un fait sur les sommes aléatoires, que les erreurs se compensent en partie. Seule la *constante* dépend de l'indicateur.

3. C'est σ, et non δ, qui gouverne la loi limite

Le TCL (théorème 5.4) dira que la somme de n copies indépendantes de X est approximativement normale, d'écart-type $\sigma\sqrt{n}$. La loi de la somme ne dépend donc, à la limite, que de σ : deux lois de même variance donnent les mêmes sommes, deux lois de même écart absolu moyen peuvent donner des sommes très différentes. Dans l'exemple 1.2, X et X' ont le même δ, mais une somme de n copies de X' s'étale comme $\sqrt{3n}$, et une somme de copies de X comme $\sqrt{n}$: δ ne permet pas de prévoir l'erreur d'une moyenne, σ le permet. Le choix de la variance est ainsi justifié *a posteriori* par le théorème qu'elle permet d'énoncer. (L'écart absolu moyen de la somme se déduit d'ailleurs de σ à la limite : $\mathbb{E}[|S_n|] \sim \sigma\sqrt{2n/\pi}$, car $\mathbb{E}[|Z|] = \sqrt{2/\pi}$ pour $Z \sim \mathcal{N}(0,1)$; ce passage à la limite dans l'espérance est admis.)

4. La variance est une distance au carré, et la moyenne la minimise

Pour tout réel c, en développant,

$$\mathbb{E}[(X-c)^2] = \mathbb{E}[(X-\mu)^2] + (\mu-c)^2 = \mathbb{V}(X) + (\mu-c)^2,$$

car le terme croisé $2(\mu-c)\,\mathbb{E}[X-\mu]$ est nul. Ainsi la moyenne μ est *la* constante la plus proche de X au sens quadratique, et la variance est le carré de cette distance minimale : c'est le théorème de Pythagore dans l'espace des variables aléatoires de carré intégrable, où $\mathbb{E}[UV]$ joue le rôle d'un produit scalaire et où des variables centrées indépendantes sont orthogonales. Moyenne et variance forment un couple cohérent. Pour l'écart absolu, la constante qui minimise $\mathbb{E}[|X-c|]$ est la *médiane*, pas la moyenne : le couple naturel est (médiane, écart absolu à la médiane), qui est le bon outil quand les données contiennent des valeurs aberrantes ou ont des queues lourdes (statistique *robuste*). L'écart absolu moyen n'est pas faux ; il ne se prête simplement pas au calcul sur les sommes.

Historiquement, Laplace mesurait d'abord les erreurs par leur valeur absolue moyenne, et butait sur les calculs. Gauss (1809) et Legendre (1805) choisissent les carrés, d'où la méthode des moindres carrés, parce qu'ils rendent les calculs linéaires ; le théorème central limite de Laplace (1810) montre ensuite que ce choix est aussi celui qui décrit la forme des erreurs. Dans toute la suite, on mesure donc la dispersion par la variance, en gardant à l'esprit que la racine carrée de σ ne sert qu'à revenir à l'unité de la grandeur mesurée.

En résumé : pourquoi la variance et pas δ

1. **On veut étudier des sommes** (une moyenne, une erreur de mesure, une marche aléatoire). Il faut donc un indicateur que l'on sache calculer sur une somme à partir des morceaux. La variance le permet : $\mathbb{V}(X+Y) = \mathbb{V}(X) + \mathbb{V}(Y)$ pour X et Y indépendantes. δ ne le permet pas : aucune formule ne donne $\delta(X+Y)$ à partir de $\delta(X)$ et $\delta(Y)$ (exemple 1.2).
2. **Ce choix commode est aussi le bon.** Le théorème central limite montre que la loi d'une somme de n copies indépendantes ne dépend, à la limite, que de σ : deux lois de même variance donnent les mêmes sommes, deux lois de même δ peuvent donner des sommes très différentes. σ contient exactement l'information qui détermine les fluctuations d'une somme ; δ non.
3. **Ce n'est pas une coïncidence.** L'additivité de la variance et son rôle dans le TCL ont la même origine : un calcul au second ordre. Les variables indépendantes centrées sont « orthogonales », donc les carrés s'ajoutent (Pythagore) ; et la preuve du TCL développe à l'ordre 2, où seuls la moyenne et la variance survivent.
4. **La racine carrée n'en est pas la cause.** La croissance en $\sqrt{n}$ est un fait sur les sommes (proposition 1.3) : elle se voit aussi avec δ. Le choix de σ ne la crée pas, il permet de la *calculer*.
5. **Hors des sommes**, δ (ou l'écart à la médiane) reste un bon indicateur, plus robuste face aux valeurs aberrantes ; il n'est simplement pas l'outil adapté à l'étude des sommes.

1.3 Variance d'une somme : l'origine des racines carrées

Proposition 1.4 (variance d'une somme de variables indépendantes)**.** Si $Y_1, \dots, Y_n$ sont indépendantes et de variance finie, alors $\mathbb{V}(Y_1 + \cdots + Y_n) = \mathbb{V}(Y_1) + \cdots + \mathbb{V}(Y_n)$. Plus généralement, pour des réels $a_1, \dots, a_n$, $\mathbb{V}(\sum_i a_i Y_i) = \sum_i a_i^2 \, \mathbb{V}(Y_i)$.

Démonstration. Posons $m_i = \mathbb{E}[Y_i]$ et $T = \sum_i a_i (Y_i - m_i)$, de sorte que $\mathbb{V}(\sum_i a_i Y_i) = \mathbb{E}[T^2]$. En développant le carré,

$$\mathbb{E}[T^2] = \sum_i a_i^2 \, \mathbb{E}\big[(Y_i - m_i)^2\big] + \sum_{i \neq j} a_i a_j \, \mathbb{E}\big[(Y_i - m_i)(Y_j - m_j)\big].$$

Pour $i \neq j$, l'indépendance donne $\mathbb{E}[(Y_i - m_i)(Y_j - m_j)] = \mathbb{E}[Y_i - m_i] \, \mathbb{E}[Y_j - m_j] = 0 \times 0 = 0$. Il reste $\sum_i a_i^2 \, \mathbb{V}(Y_i)$. ∎

Corollaire 1.5 (écart-type d'une moyenne)**.** $\mathbb{E}[\overline{X}_n] = \mu$ et $\mathbb{V}(\overline{X}_n) = \dfrac{\sigma^2}{n}$, donc l'écart-type de $\overline{X}_n$ vaut $\boxed{\dfrac{\sigma}{\sqrt{n}}}$.

Démonstration. Linéarité de l'espérance, puis proposition 1.4 avec $a_i = 1/n$: $\mathbb{V}(\overline{X}_n) = n \times \frac{1}{n^2} \sigma^2$. ∎

Tout est là : **les erreurs indépendantes ne s'additionnent pas, ce sont leurs carrés (les variances) qui s'additionnent.** La somme de n erreurs d'écart-type σ a pour écart-type $\sigma\sqrt{n}$, et non $n\sigma$: les erreurs se compensent en partie. En divisant par n, la moyenne a un écart-type $\sigma/\sqrt{n}$. Pour diviser l'erreur par 2, il faut donc 4 fois plus de mesures ; pour la diviser par 10, 100 fois plus.

Pour un sondage, $\sigma^2 = \mathbb{V}(X_1) = p(1-p) \leq \frac{1}{4}$ (le maximum du trinôme est atteint en $p = \frac{1}{2}$), donc l'écart-type de $\widehat{p}_n$ est au plus $\frac{1}{2\sqrt{n}}$, soit environ 1,6 point pour $n = 1\,000$.

1.4 Une première marge, par Bienaymé-Tchebychev

Proposition 1.6 (inégalité de Bienaymé-Tchebychev)**.** Si Y admet une variance, pour tout $\varepsilon > 0$, $\mathbb{P}(|Y - \mathbb{E}[Y]| \geq \varepsilon) \leq \dfrac{\mathbb{V}(Y)}{\varepsilon^2}$.

Démonstration. On a $\varepsilon^2 \, \mathbf{1}_{\{|Y-\mathbb{E}[Y]|\geq\varepsilon\}} \leq (Y - \mathbb{E}[Y])^2$ (si l'indicatrice vaut 1, le carré est $\geq \varepsilon^2$; sinon le membre de gauche est nul). On prend l'espérance : $\varepsilon^2 \, \mathbb{P}(|Y - \mathbb{E}[Y]| \geq \varepsilon) \leq \mathbb{V}(Y)$. ■

Corollaire 1.7 (loi faible des grands nombres)**.** Pour tout $\varepsilon > 0$,

$$\mathbb{P}(|\overline{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow[n\to+\infty]{} 0.$$

Démonstration. Proposition 1.6 appliquée à $\overline{X}_n$, avec $\mathbb{V}(\overline{X}_n) = \sigma^2/n$. ■

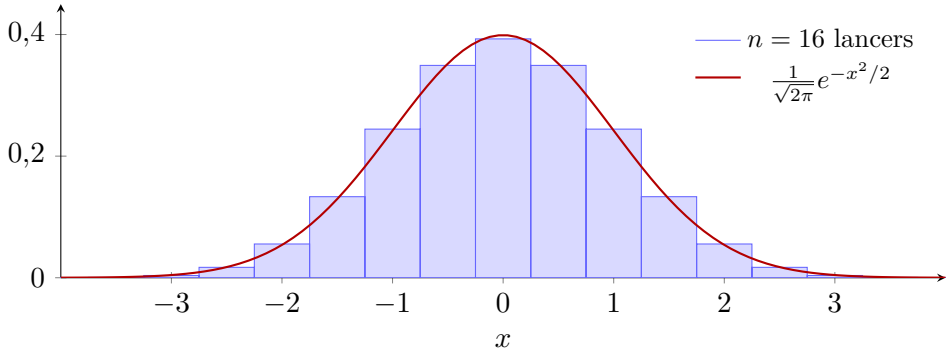
Application 1.1 — la marge d'un sondage, version prudente

On cherche ε tel que $\mathbb{P}(|\widehat{p}_n - p| \geq \varepsilon) \leq 5\,\%$. Comme $\sigma^2 \leq \frac{1}{4}$, il suffit que $\frac{1}{4n\varepsilon^2} \leq 0{,}05$, soit $\varepsilon = \frac{1}{2\sqrt{0{,}05\,n}}$. Pour $n = 1\,000$, on obtient $\varepsilon \approx 7{,}1$ points.

Ce résultat est *vrai*, mais très pessimiste : les instituts annoncent 3,1 points, et ils ont raison. Bienaymé-Tchebychev n'utilise que la variance ; il doit valoir pour *toutes* les lois de variance donnée, y compris les plus défavorables. Pour faire mieux, il faut connaître la *forme* de la loi de $\widehat{p}_n$, pas seulement sa dispersion. C'est ce que donne le théorème central limite : la loi de $\widehat{p}_n$ est presque une loi normale, et pour une loi normale la probabilité d'être à plus de 1,96 écart-type de la moyenne vaut exactement 5 %, au lieu de la borne $1/1{,}96^2 \approx 26\,\%$ de Tchebychev.

2 Ce que l'on observe : la forme en cloche

Lançons n fois une pièce équilibrée et comptons les « pile » : S_n suit la loi binomiale $\mathcal{B}(n, \frac{1}{2})$. Quand n grandit, l'histogramme de la variable centrée réduite $\frac{S_n - n/2}{\sqrt{n}/2}$ épouse une courbe en cloche fixe, celle de la densité $\frac{1}{\sqrt{2\pi}} e^{-x^2/2}$.



Loi du nombre de « pile » sur 16 lancers, centrée et réduite (chaque barre a une aire égale à sa probabilité), et densité de la loi normale centrée réduite. L'accord est déjà très bon pour $n = 16$.

Le phénomène est universel : avec un dé au lieu d'une pièce, ou des durées de vie, ou des erreurs de mesure de loi quelconque, la courbe limite est la même. Il faut donc étudier cette courbe (partie B), puis démontrer qu'elle est la limite (partie C).

Partie B — La loi normale

3 L'intégrale de Gauss et la loi normale

La courbe limite observée est celle de $x \mapsto e^{-x^2/2}$, à une constante près. Pour en faire une densité de probabilité, il faut que son intégrale vaille 1 : on doit donc calculer $\int_{\mathbb{R}} e^{-x^2/2}\,\mathrm{d}x$. Ce calcul n'est pas évident, car $e^{-x^2/2}$ n'a pas de primitive exprimable avec les fonctions usuelles ; l'astuce consiste à passer par une intégrale double.

Proposition 3.1 (intégrale de Gauss)**.** $\displaystyle\int_{-\infty}^{+\infty} e^{-x^2/2}\,\mathrm{d}x = \sqrt{2\pi}.$

Démonstration. La fonction est positive, continue, et majorée par $e^{1/2-|x|}$ (car $x^2/2 \geq |x| - \frac{1}{2}$) : l'intégrale converge. Par parité, il suffit de montrer que $J = \displaystyle\int_0^{+\infty} e^{-x^2}\,\mathrm{d}x$ vaut $\frac{\sqrt{\pi}}{2}$ (le changement de variable $x = u/\sqrt{2}$ ramène $e^{-x^2/2}$ à e^{-u^2}, d'où $\displaystyle\int_{\mathbb{R}} e^{-x^2/2}\,\mathrm{d}x = 2\sqrt{2}\,J$). Par Fubini-Tonelli (fonction positive),

$$J^2 = \int_0^{+\infty}\int_0^{+\infty} e^{-x^2-y^2}\,\mathrm{d}y\,\mathrm{d}x.$$

À $x > 0$ fixé, le changement de variable $y = xt$ dans l'intégrale intérieure donne $\displaystyle\int_0^{+\infty} e^{-x^2(1+t^2)}\,x\,\mathrm{d}t$. On échange à nouveau les intégrales (Tonelli) :

$$J^2 = \int_0^{+\infty}\left(\int_0^{+\infty} x\,e^{-x^2(1+t^2)}\,\mathrm{d}x\right)\mathrm{d}t = \int_0^{+\infty} \frac{1}{2(1+t^2)}\,\mathrm{d}t = \frac{1}{2}\cdot\frac{\pi}{2} = \frac{\pi}{4},$$

car, pour $c > 0$,

$$\int_0^{+\infty} x\,e^{-cx^2}\,\mathrm{d}x = \Big[-\frac{e^{-cx^2}}{2c}\Big]_0^{+\infty} = \frac{1}{2c}.$$

Donc $J = \frac{\sqrt{\pi}}{2}$ et $\displaystyle\int_{\mathbb{R}} e^{-x^2/2}\,\mathrm{d}x = 2\sqrt{2}\cdot\frac{\sqrt{\pi}}{2} = \sqrt{2\pi}.$ ∎

Définition 3.2 (loi normale)**.** Une variable Z suit la **loi normale centrée réduite** $\mathcal{N}(0,1)$ si elle a pour densité $\varphi(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$; on note $\Phi(x) = \mathbb{P}(Z \leq x) = \displaystyle\int_{-\infty}^{x} \varphi$ sa fonction de répartition. Pour $m \in \mathbb{R}$ et $s > 0$, la variable $m + sZ$ suit la loi $\mathcal{N}(m, s^2)$, de densité $\frac{1}{s\sqrt{2\pi}}e^{-(x-m)^2/(2s^2)}$. Par convention, $\mathcal{N}(m,0)$ est la loi constante égale à m.

Pour pouvoir remplacer une variable X_i par une variable normale sans changer la moyenne ni la variance, il faut connaître l'espérance et la variance de la loi normale ; la preuve du TCL aura aussi besoin d'une majoration de $\mathbb{E}[|Z|^3]$, pour contrôler le reste d'ordre 3 d'une formule de Taylor.

Proposition 3.3 (moments)**.** Si $Z \sim \mathcal{N}(0,1)$: $\mathbb{E}[Z] = 0$, $\mathbb{E}[Z^2] = 1$, $\mathbb{E}[|Z|^3] = 2\sqrt{2/\pi} \approx 1{,}60$. Donc $\mathbb{E}[m + sZ] = m$ et $\mathbb{V}(m + sZ) = s^2$.

Démonstration. φ est paire et $x\varphi(x)$ est intégrable, donc $\mathbb{E}[Z] = 0$. Par intégration par parties sur $[0, A]$ puis $A \to +\infty$, avec $\varphi'(x) = -x\varphi(x)$:

$$\int_0^{+\infty} x^2\varphi(x)\,\mathrm{d}x = \big[-x\varphi(x)\big]_0^{+\infty} + \int_0^{+\infty} \varphi(x)\,\mathrm{d}x = 0 + \frac{1}{2},$$

donc $\mathbb{E}[Z^2] = 2 \times \frac{1}{2} = 1$. Enfin, par la même intégration par parties,

$$\mathbb{E}[|Z|^3] = 2\int_0^{+\infty} x^3 \varphi(x)\,\mathrm{d}x = 2\Big(\big[-x^2\varphi(x)\big]_0^{+\infty} + \int_0^{+\infty} 2x\varphi(x)\,\mathrm{d}x\Big) = 4\varphi(0) = \frac{4}{\sqrt{2\pi}}.$$

■

La propriété suivante est la clé de tout le document. Elle dit que, pour des variables normales, le TCL est *exact* et pas seulement asymptotique ; c'est ce qui permettra de démontrer le cas général par comparaison.

Proposition 3.4 (stabilité)**.** Si $U \sim \mathcal{N}(0, a^2)$ et $V \sim \mathcal{N}(0, b^2)$ sont indépendantes $(a, b > 0)$, alors $U + V \sim \mathcal{N}(0, a^2 + b^2)$. Par récurrence, une somme de variables normales centrées indépendantes est normale centrée, de variance la somme des variances.

Démonstration. La densité de $U + V$ est la convolée $h(z) = \displaystyle\int_{\mathbb{R}} f_U(x) f_V(z - x)\,\mathrm{d}x$, soit

$$h(z) = \frac{1}{2\pi ab}\int_{\mathbb{R}} \exp\Big(-\frac{x^2}{2a^2} - \frac{(z-x)^2}{2b^2}\Big)\,\mathrm{d}x.$$

Posons $c^2 = a^2 + b^2$. On complète le carré en x : on vérifie en développant que

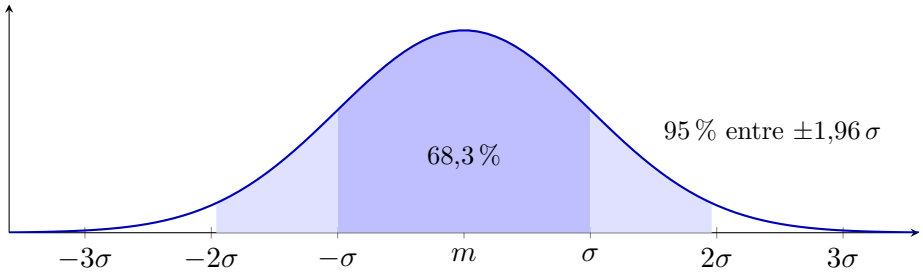
$$\frac{x^2}{a^2} + \frac{(z-x)^2}{b^2} = \frac{c^2}{a^2 b^2}\Big(x - \frac{a^2 z}{c^2}\Big)^2 + \frac{z^2}{c^2}.$$

(Le coefficient de x^2 vaut $\frac{1}{a^2} + \frac{1}{b^2} = \frac{c^2}{a^2b^2}$, celui de x vaut $-\frac{2z}{b^2}$ des deux côtés, et le terme constant du membre de droite vaut $\frac{c^2}{a^2b^2}\cdot\frac{a^4 z^2}{c^4} + \frac{z^2}{c^2} = \frac{z^2}{c^2}\big(\frac{a^2}{b^2} + 1\big) = \frac{z^2}{b^2}$.) Le changement de variable $x = \frac{a^2 z}{c^2} + \frac{ab}{c}u$ et la proposition 3.1 donnent

$$h(z) = \frac{1}{2\pi ab}\, e^{-z^2/(2c^2)} \cdot \frac{ab}{c}\int_{\mathbb{R}} e^{-u^2/2}\,\mathrm{d}u = \frac{1}{c\sqrt{2\pi}}\, e^{-z^2/(2c^2)},$$

qui est la densité de $\mathcal{N}(0, c^2)$. ■

Remarque 3.5 (pourquoi la loi normale est « la » limite)**.** Si $Z_1, \dots, Z_n$ sont indépendantes de loi $\mathcal{N}(0,1)$, la proposition donne $\frac{Z_1 + \cdots + Z_n}{\sqrt{n}} \sim \mathcal{N}(0,1)$: la loi normale est *invariante* par l'opération « additionner des copies indépendantes et diviser par $\sqrt{n}$ ». Si cette opération, appliquée à une loi quelconque, converge vers quelque chose, ce ne peut être qu'une loi invariante. La preuve de Lindeberg exploite exactement cette remarque : comme l'énoncé est *exact* pour des variables normales, il suffit de montrer que remplacer les X_i par des normales de même moyenne et de même variance ne change presque rien.



Pour une loi normale : $\mathbb{P}(|Z| \le 1) = 2\Phi(1) - 1 \approx 68{,}3\,\%$, $\mathbb{P}(|Z| \le 1{,}96) \approx 95\,\%$, $\mathbb{P}(|Z| \le 2) \approx 95{,}4\,\%$, $\mathbb{P}(|Z| \le 3) \approx 99{,}7\,\%$. *Ce sont les « niveaux de confiance » des sondages et des incertitudes élargies.*

Partie C — Le théorème central limite et sa preuve

4 Convergence en loi, et comment la démontrer

Définition 4.1 (convergence en loi vers une loi normale)**.** Une suite (Y_n) de variables aléatoires **converge en loi** vers $\mathcal{N}(0,1)$, et l'on note $Y_n \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$, si pour tout réel x, $\mathbb{P}(Y_n \le x) \to \Phi(x)$.

C'est exactement ce qu'il faut pour les applications : on veut approcher

$$\mathbb{P}(a < Y_n \le b) = \mathbb{P}(Y_n \le b) - \mathbb{P}(Y_n \le a) \quad \text{par} \quad \Phi(b) - \Phi(a).$$

Mais les fonctions indicatrices $\mathbf{1}_{]-\infty,x]}$ sont discontinues, donc impropres à un développement de Taylor. On passe par des fonctions lisses.

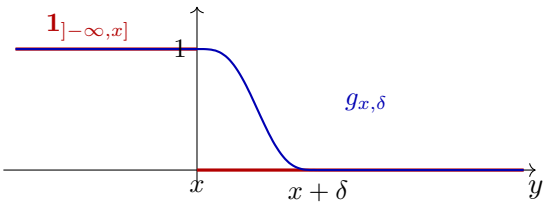
Définition 4.2. On note $\mathcal{C}^3_b$ l'ensemble des fonctions $g : \mathbb{R} \to \mathbb{R}$ de classe $\mathcal{C}^3$ dont les dérivées g', g'', g''' et g elle-même sont bornées ; on note $\|h\|_\infty = \sup_{\mathbb{R}} |h|$.

Lemme 4.3 (une marche lissée)**.** Soit $\psi(t) = 1 - (35t^4 - 84t^5 + 70t^6 - 20t^7)$ pour $t \in [0,1]$, $\psi(t) = 1$ pour $t < 0$ et $\psi(t) = 0$ pour $t > 1$. Alors ψ est de classe $\mathcal{C}^3$ sur $\mathbb{R}$, décroissante, à valeurs dans $[0,1]$. Pour $x \in \mathbb{R}$ et $\delta > 0$, la fonction $g_{x,\delta}(y) = \psi\big(\frac{y-x}{\delta}\big)$ appartient à $\mathcal{C}^3_b$ et vérifie $\mathbf{1}_{]-\infty,x]} \le g_{x,\delta} \le \mathbf{1}_{]-\infty,x+\delta]}$.

Démonstration. Posons $P(t) = 35t^4 - 84t^5 + 70t^6 - 20t^7$. On calcule

$$P'(t) = 140t^3 - 420t^4 + 420t^5 - 140t^6 = 140\, t^3(1-t)^3.$$

Donc $P(0) = 0$, $P(1) = 35 - 84 + 70 - 20 = 1$, P est croissante sur $[0,1]$, et P' s'annule à l'ordre 3 en 0 et en 1 : P', P'', P''' y sont nulles. Ainsi ψ se raccorde avec les constantes 1 et 0, ainsi que ses trois premières dérivées : elle est $\mathcal{C}^3$ sur $\mathbb{R}$, décroissante, à valeurs dans $[0,1]$, et ses dérivées sont bornées (polynômes sur $[0,1]$, nulles ailleurs). Si $y \le x$, $g_{x,\delta}(y) = 1$; si $y > x + \delta$, $g_{x,\delta}(y) = 0$; entre les deux, $g_{x,\delta}(y) \in [0,1]$: d'où l'encadrement. ∎



L'indicatrice de $]-\infty, x]$ (en rouge) est majorée par la marche lissée $g_{x,\delta}$ (en bleu), qui vaut 1 jusqu'en x et 0 après $x+\delta$, avec trois dérivées continues.

Proposition 4.4 (il suffit de tester des fonctions lisses)**.** Soit (Y_n) une suite de variables aléatoires et $Z \sim \mathcal{N}(0,1)$. Si $\mathbb{E}[g(Y_n)] \to \mathbb{E}[g(Z)]$ pour toute $g \in \mathcal{C}^3_b$, alors $Y_n \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$.

Démonstration. Soit $x \in \mathbb{R}$ et $\delta > 0$. Par le lemme 4.3 et la croissance de l'espérance,

$$\mathbb{P}(Y_n \le x) \le \mathbb{E}[g_{x,\delta}(Y_n)] \xrightarrow[n\to+\infty]{} \mathbb{E}[g_{x,\delta}(Z)] \le \mathbb{P}(Z \le x+\delta) = \Phi(x+\delta),$$

$$\mathbb{P}(Y_n \le x) \ge \mathbb{E}[g_{x-\delta,\delta}(Y_n)] \xrightarrow[n\to+\infty]{} \mathbb{E}[g_{x-\delta,\delta}(Z)] \ge \mathbb{P}(Z \le x-\delta) = \Phi(x-\delta).$$

Donc $\Phi(x-\delta) \le \liminf \mathbb{P}(Y_n \le x) \le \limsup \mathbb{P}(Y_n \le x) \le \Phi(x+\delta)$. La fonction Φ est continue (c'est une primitive) : en faisant tendre δ vers 0, la limite existe et vaut $\Phi(x)$. ■

Dernier outil avant la preuve. Celle-ci consistera à développer $g(w+h)$ à l'ordre 2 en h, où h sera une petite contribution X_i/s_n, et à contrôler le reste. Comme on ne suppose qu'une variance finie, il faut une majoration du reste qui reste utilisable quand h est grand (où seul h^2 est intégrable) comme quand h est petit (où $|h|^3$ est bien plus petit que h^2).

Lemme 4.5 (Taylor avec deux majorations)**.** Pour $g \in \mathcal{C}^3_b$ et $a, h \in \mathbb{R}$, le reste $R_g(a,h) = g(a+h) - g(a) - g'(a)h - \frac{1}{2}g''(a)h^2$ vérifie

$$|R_g(a,h)| \le \min\Big(\|g''\|_\infty\, h^2,\ \frac{\|g'''\|_\infty}{6}|h|^3\Big).$$

Démonstration. Taylor-Lagrange à l'ordre 3 donne c entre a et $a+h$ avec $R_g(a,h) = \frac{g'''(c)}{6}h^3$, d'où la seconde majoration. À l'ordre 2, il existe c' avec $g(a+h) = g(a) + g'(a)h + \frac{1}{2}g''(c')h^2$, donc $R_g(a,h) = \frac{1}{2}(g''(c') - g''(a))h^2$, de valeur absolue au plus $\frac{1}{2}\cdot 2\|g''\|_\infty h^2$. ■

La première majoration sert pour les grandes valeurs de h, la seconde pour les petites. C'est ce qui permet de ne supposer qu'une variance finie, et non un moment d'ordre 3.

5 Le théorème de Lindeberg

L'idée de la preuve

Pourquoi la loi limite ne dépend-elle que de la moyenne et de la variance ? Soit g une fonction lisse et h une petite contribution aléatoire, indépendante de w. Le développement de Taylor

$$\mathbb{E}[g(w+h)] \approx \mathbb{E}[g(w)] + \mathbb{E}[g'(w)]\,\mathbb{E}[h] + \tfrac{1}{2}\,\mathbb{E}[g''(w)]\,\mathbb{E}[h^2]$$

montre que, jusqu'à l'ordre 2, seules l'espérance et la variance de h comptent. Le reste est d'ordre $\mathbb{E}[|h|^3]$. Si $h = X_i/s_n$ avec $s_n \approx \sigma\sqrt{n}$, ce reste est en $n^{-3/2}$; en l'additionnant sur les n contributions, on obtient un terme en $n^{-1/2}$, qui tend vers 0. Remplacer chaque X_i par une variable normale de même moyenne et de même variance ne change donc presque rien. Or, pour des variables normales, la somme renormalisée suit *exactement* la loi $\mathcal{N}(0,1)$ (proposition 3.4). La loi de S_n/s_n est donc proche de $\mathcal{N}(0,1)$: c'est la méthode de remplacement de Lindeberg. La preuve rend rigoureux ce calcul, en remplaçant le moment d'ordre 3, qu'on ne suppose pas fini, par une coupure au niveau εs_n.

On démontre d'abord une version où les variables n'ont pas toutes la même loi. Elle servira en physique (une erreur de mesure est la somme de petites perturbations de natures différentes), et le cas des variables de même loi en sera un corollaire.

Théorème 5.1 (Lindeberg, 1922)**.** Soit $X_1, X_2, \dots$ des variables aléatoires indépendantes, centrées, de variances $\sigma_i^2 = \mathbb{E}[X_i^2]$ finies. On pose $S_n = X_1 + \cdots + X_n$ et $s_n^2 = \sigma_1^2 + \cdots + \sigma_n^2$, supposé non nul. On suppose la **condition de Lindeberg** : pour tout $\varepsilon > 0$,

$$L_n(\varepsilon) = \frac{1}{s_n^2}\sum_{i=1}^{n} \mathbb{E}\big[X_i^2\, \mathbf{1}_{\{|X_i| > \varepsilon s_n\}}\big] \xrightarrow[n\to+\infty]{} 0.$$

Alors $\dfrac{S_n}{s_n} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$.

Démonstration. Fixons n et notons $s = s_n$. Soit $Z \sim \mathcal{N}(0,1)$. Par la proposition 4.4, il suffit de montrer que, pour toute $g \in \mathcal{C}_b^3$,

$$\mathbb{E}\Big[g\Big(\frac{S_n}{s_n}\Big)\Big] - \mathbb{E}[g(Z)] \xrightarrow[n\to+\infty]{} 0.$$

Fixons g.

Étape 1 : les variables de remplacement. Soit $Z_1, \dots, Z_n$ des variables indépendantes entre elles et des X_i, avec $Z_i \sim \mathcal{N}(0, \sigma_i^2)$. Par la proposition 3.4, $T = \frac{Z_1+\cdots+Z_n}{s}$ suit la loi $\mathcal{N}(0,1)$, donc $\mathbb{E}[g(T)] = \mathbb{E}[g(Z)]$. On va passer de S_n/s à T en remplaçant les X_i par les Z_i un par un.

Étape 2 : la somme télescopique. Pour $1 \le i \le n$, posons

$$W_i = \frac{X_1 + \cdots + X_{i-1} + Z_{i+1} + \cdots + Z_n}{s}.$$

Alors

$$W_i + \frac{X_i}{s} = \frac{X_1 + \cdots + X_i + Z_{i+1} + \cdots + Z_n}{s}, \qquad W_i + \frac{Z_i}{s} = \frac{X_1 + \cdots + X_{i-1} + Z_i + \cdots + Z_n}{s},$$

si bien que $W_i + \frac{Z_i}{s} = W_{i-1} + \frac{X_{i-1}}{s}$ pour $i \ge 2$, que $W_n + \frac{X_n}{s} = \frac{S_n}{s}$ et que $W_1 + \frac{Z_1}{s} = T$. D'où

$$g\Big(\frac{S_n}{s}\Big) - g(T) = \sum_{i=1}^{n} \Big[g\Big(W_i + \frac{X_i}{s}\Big) - g\Big(W_i + \frac{Z_i}{s}\Big)\Big].$$

Étape 3 : un remplacement. Par le lemme 4.5,

$$g\Big(W_i + \frac{X_i}{s}\Big) = g(W_i) + g'(W_i)\frac{X_i}{s} + \frac{1}{2}g''(W_i)\frac{X_i^2}{s^2} + R_g\Big(W_i, \frac{X_i}{s}\Big),$$

et de même avec Z_i. La variable W_i ne fait intervenir ni X_i ni Z_i : elle est indépendante de X_i et de Z_i. Donc

$$\mathbb{E}[g'(W_i)X_i] = \mathbb{E}[g'(W_i)]\,\mathbb{E}[X_i] = 0 = \mathbb{E}[g'(W_i)Z_i], \qquad \mathbb{E}[g''(W_i)X_i^2] = \mathbb{E}[g''(W_i)]\,\sigma_i^2 = \mathbb{E}[g''(W_i)Z_i^2].$$

Les termes d'ordre 0, 1 et 2 ont la même espérance : c'est ici que servent l'égalité des moyennes et des variances. Il reste

$$\Big|\mathbb{E}\Big[g\Big(W_i + \frac{X_i}{s}\Big)\Big] - \mathbb{E}\Big[g\Big(W_i + \frac{Z_i}{s}\Big)\Big]\Big| \le \mathbb{E}\Big[\Big|R_g\Big(W_i, \frac{X_i}{s}\Big)\Big|\Big] + \mathbb{E}\Big[\Big|R_g\Big(W_i, \frac{Z_i}{s}\Big)\Big|\Big].$$

Étape 4 : les restes des X_i. Soit $\varepsilon > 0$. Sur l'événement $\{|X_i| > \varepsilon s\}$, on utilise la majoration $\|g''\|_\infty X_i^2/s^2$; sur $\{|X_i| \le \varepsilon s\}$, la majoration $\frac{\|g'''\|_\infty}{6}|X_i|^3/s^3 \le \frac{\|g'''\|_\infty}{6}\,\varepsilon\, X_i^2/s^2$. Donc

$$\mathbb{E}\Big[\Big|R_g\Big(W_i, \frac{X_i}{s}\Big)\Big|\Big] \le \frac{\|g''\|_\infty}{s^2}\,\mathbb{E}[X_i^2 \mathbf{1}_{\{|X_i|>\varepsilon s\}}] + \frac{\|g'''\|_\infty\,\varepsilon}{6}\cdot\frac{\sigma_i^2}{s^2},$$

et, en sommant sur i (avec $\sum_i \sigma_i^2 = s^2$) : $\sum_i \mathbb{E}[|R_g(W_i, X_i/s)|] \le \|g''\|_\infty\, L_n(\varepsilon) + \frac{\|g'''\|_\infty}{6}\,\varepsilon$.

Étape 5 : les restes des Z_i. On utilise la seconde majoration, et le fait que Z_i a même loi que $\sigma_i Z$, donc $\mathbb{E}[|Z_i|^3] = \sigma_i^3\,\mathbb{E}[|Z|^3] \le 2\sigma_i^3$ (proposition 3.3) :

$$\sum_i \mathbb{E}\Big[\Big|R_g\Big(W_i, \frac{Z_i}{s}\Big)\Big|\Big] \le \frac{\|g'''\|_\infty}{6s^3}\sum_i 2\sigma_i^3 \le \frac{\|g'''\|_\infty}{3}\cdot\frac{\max_i \sigma_i}{s}\cdot\frac{\sum_i \sigma_i^2}{s^2} = \frac{\|g'''\|_\infty}{3}\cdot\frac{\max_i \sigma_i}{s}.$$

Or, pour tout i, en coupant selon $|X_i| \le \varepsilon s$ ou non, $\sigma_i^2 \le \varepsilon^2 s^2 + \mathbb{E}[X_i^2 \mathbf{1}_{\{|X_i|>\varepsilon s\}}] \le \varepsilon^2 s^2 + s^2 L_n(\varepsilon)$, donc $\frac{\max_i \sigma_i}{s} \le \sqrt{\varepsilon^2 + L_n(\varepsilon)}$.

Étape 6 : conclusion. En réunissant les étapes 2 à 5,

$$\left|\mathbb{E}\Big[g\Big(\frac{S_n}{s_n}\Big)\Big] - \mathbb{E}[g(Z)]\right| \leq \|g''\|_\infty\, L_n(\varepsilon) + \frac{\|g'''\|_\infty}{6}\,\varepsilon + \frac{\|g'''\|_\infty}{3}\sqrt{\varepsilon^2 + L_n(\varepsilon)}.$$

Quand $n \to +\infty$, $L_n(\varepsilon) \to 0$, donc la limite supérieure du membre de gauche est au plus

$$\frac{\|g'''\|_\infty}{6}\,\varepsilon + \frac{\|g'''\|_\infty}{3}\,\varepsilon = \frac{\|g'''\|_\infty}{2}\,\varepsilon.$$

Comme $\varepsilon > 0$ est arbitraire, elle est nulle. ■

Remarque 5.2 (ce que dit la condition de Lindeberg)**.** L'étape 5 montre qu'elle entraîne que $\max_i \sigma_i / s_n$ tend vers 0 : *aucune contribution ne pèse de façon notable dans la somme.* C'est la traduction mathématique de l'idée « une somme de nombreuses petites causes indépendantes, dont aucune ne domine ». Si une seule cause domine (un X_1 de variance énorme), la somme a la loi de cette cause, qui n'a aucune raison d'être normale.

5.1 Le cas de variables de même loi

Pour des variables de même loi, la condition de Lindeberg porte sur une seule variable : il faut montrer que la contribution des grandes valeurs à sa variance est négligeable. C'est l'objet du lemme suivant.

Lemme 5.3 (queue d'un moment d'ordre 2)**.** Si $\mathbb{E}[X^2] < +\infty$, alors $\mathbb{E}\big[X^2\,\mathbf{1}_{\{|X|>M\}}\big] \to 0$ quand $M \to +\infty$.

Démonstration. Si X est discrète, de valeurs x_k prises avec probabilités p_k, $\mathbb{E}[X^2] = \sum_k x_k^2 p_k$ est une série convergente à termes positifs, et $\mathbb{E}[X^2\mathbf{1}_{\{|X|>M\}}] = \sum_{|x_k|>M} x_k^2 p_k$ est majoré par le reste de cette série au-delà d'un rang qui tend vers l'infini avec M : il tend vers 0. Si X a une densité f, $\mathbb{E}[X^2\mathbf{1}_{\{|X|>M\}}] = \displaystyle\int_{|x|>M} x^2 f(x)\,\mathrm{d}x$ est le reste d'une intégrale généralisée convergente, qui tend vers 0. (Dans le cas général, c'est le théorème de convergence monotone de la théorie de l'intégration ; les deux cas ci-dessus couvrent tous les exemples de ce document.) ■

Théorème 5.4 (théorème central limite, Lindeberg-Lévy)**.** Soit $X_1, X_2, \ldots$ indépendantes, de même loi, d'espérance μ et de variance $\sigma^2 \in\,]0, +\infty[$. Alors

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{\sqrt{n}\,(\overline{X}_n - \mu)}{\sigma} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1),$$

c'est-à-dire, pour tous réels $a < b$,

$$\mathbb{P}\Big(a < \frac{\sqrt{n}\,(\overline{X}_n - \mu)}{\sigma} \leq b\Big) \xrightarrow[n\to+\infty]{} \Phi(b) - \Phi(a).$$

Démonstration. Les variables $Y_i = X_i - \mu$ sont indépendantes, centrées, de variance σ^2 ; $s_n = \sigma\sqrt{n}$. Comme elles ont même loi,

$$L_n(\varepsilon) = \frac{1}{n\sigma^2} \cdot n\,\mathbb{E}\big[Y_1^2\,\mathbf{1}_{\{|Y_1|>\varepsilon\sigma\sqrt{n}\}}\big] = \frac{1}{\sigma^2}\mathbb{E}\big[Y_1^2\,\mathbf{1}_{\{|Y_1|>\varepsilon\sigma\sqrt{n}\}}\big],$$

qui tend vers 0 par le lemme 5.3 (avec $M = \varepsilon\sigma\sqrt{n} \to +\infty$). Le théorème 5.1 s'applique. La seconde formulation s'en déduit en écrivant $\mathbb{P}(a < Y \leq b) = \mathbb{P}(Y \leq b) - \mathbb{P}(Y \leq a)$. ■

Corollaire 5.5 (de Moivre-Laplace)**.** Si $S_n \sim \mathcal{B}(n,p)$ avec $p \in]0,1[$, alors

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1).$$

Démonstration. S_n a même loi qu'une somme de n variables de Bernoulli indépendantes de paramètre p, d'espérance p et de variance $p(1-p)$: c'est le théorème 5.4. ■

Application 5.1 — la planche de Galton, 100 lancers

Pour 100 lancers d'une pièce équilibrée, $\mathbb{P}(40 \le S_{100} \le 60)$ vaut exactement 0,9648. L'approximation normale donne $\mathbb{P}(|Z| \le 2) \approx 0{,}9545$; en remplaçant les bornes par 39,5 et 60,5 (« correction de continuité » : la barre de l'entier k couvre $[k-\frac{1}{2}, k+\frac{1}{2}]$), on obtient $\mathbb{P}(|Z| \le 2{,}1) \approx 0{,}9643$, très proche de la vraie valeur.

Pour aller plus loin

Vitesse de convergence. Le théorème de Berry-Esseen (admis ici) précise l'erreur : si $\mathbb{E}[|X_1-\mu|^3] = \rho < +\infty$, alors $\sup_x |\mathbb{P}(\frac{\sqrt{n}(\overline{X}_n-\mu)}{\sigma} \le x) - \Phi(x)| \le \frac{C\rho}{\sigma^3\sqrt{n}}$, avec une constante universelle $C < 0{,}48$. L'erreur de l'approximation normale décroît donc en $1/\sqrt{n}$: excellente pour un sondage ($n = 1\,000$), médiocre pour 5 mesures.
Sans variance, pas de TCL. Si X_1 suit la loi de Cauchy (densité $\frac{1}{\pi(1+x^2)}$, sans espérance ni variance), la moyenne $\overline{X}_n$ suit encore la loi de Cauchy, pour tout n : moyenner ne sert à rien. Les mesures « à queue lourde » échappent à toute la théorie de ce document.

6 Deux outils pour les applications : Slutsky et la méthode delta

En pratique, on ne connaît ni μ ni σ : on remplace σ par une estimation, et on s'intéresse souvent à une fonction de la moyenne plutôt qu'à la moyenne elle-même. Deux lemmes élémentaires permettent ces manipulations.

Définition 6.1 (convergence en probabilité)**.** On dit que A_n converge en probabilité vers le réel a, et l'on note $A_n \xrightarrow[n\to+\infty]{\mathbb{P}} a$, si pour tout $\delta > 0$, $\mathbb{P}(|A_n - a| > \delta) \to 0$. Par exemple, $\overline{X}_n$ converge en probabilité vers μ (corollaire 1.7).

Lemme 6.2 (fonctions continues)**.** Si A_n converge en probabilité vers a et si h est continue en a, alors $h(A_n)$ converge en probabilité vers $h(a)$.

Démonstration. Soit $\delta > 0$ et $\eta > 0$ tel que $|y-a| \le \eta \Rightarrow |h(y)-h(a)| \le \delta$. Alors

$$\{|h(A_n) - h(a)| > \delta\} \subset \{|A_n - a| > \eta\},$$

dont la probabilité tend vers 0. ■

Lemme 6.3 (Slutsky)**.** Soit $Y_n \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$.

1. **(tension)** Pour tout $\eta > 0$, il existe $K > 0$ et n_0 tels que $\mathbb{P}(|Y_n| > K) \le \eta$ pour $n \ge n_0$.
2. Si $R_n \xrightarrow[n\to+\infty]{\mathbb{P}} 0$, alors $Y_n + R_n \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$.
3. Si $A_n \xrightarrow[n\to+\infty]{\mathbb{P}} 1$, alors $A_n Y_n \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$.

Démonstration. 1. Choisissons K avec $\Phi(K) - \Phi(-K) \geq 1 - \eta/2$. Comme

$$\mathbb{P}(|Y_n| > K) \leq 1 - \mathbb{P}(-K < Y_n \leq K) \xrightarrow[n\to+\infty]{} 1 - \big(\Phi(K) - \Phi(-K)\big) \leq \frac{\eta}{2},$$

on a $\mathbb{P}(|Y_n| > K) \leq \eta$ pour n assez grand.

2. Soit $x \in \mathbb{R}$ et $\delta > 0$. On a

$$\{Y_n + R_n \leq x\} \subset \{Y_n \leq x + \delta\} \cup \{|R_n| > \delta\},$$

donc $\limsup \mathbb{P}(Y_n + R_n \leq x) \leq \Phi(x + \delta)$. De même $\{Y_n \leq x - \delta\} \subset \{Y_n + R_n \leq x\} \cup \{|R_n| > \delta\}$ donne $\liminf \mathbb{P}(Y_n + R_n \leq x) \geq \Phi(x - \delta)$. On fait tendre δ vers 0 (Φ est continue).

3. On écrit $A_nY_n = Y_n + (A_n - 1)Y_n$ et l'on montre que $(A_n - 1)Y_n \xrightarrow[n\to+\infty]{\mathbb{P}} 0$. Soit $\delta, \eta > 0$, et K donné par le point 1. Alors

$$\mathbb{P}(|(A_n - 1)Y_n| > \delta) \leq \mathbb{P}(|Y_n| > K) + \mathbb{P}\Big(|A_n - 1| > \frac{\delta}{K}\Big) \leq \eta + \mathbb{P}\Big(|A_n - 1| > \frac{\delta}{K}\Big),$$

dont la limite supérieure est au plus η, arbitraire. On conclut par le point 2. ■

Le cas typique est celui de la physique : on mesure plusieurs fois une période T, mais la grandeur qui intéresse est $g = 4\pi^2 L/T^2$, une fonction non linéaire de la moyenne. L'idée est de linéariser : près de μ, $f(\overline{X}_n) - f(\mu) \approx f'(\mu)(\overline{X}_n - \mu)$, et une variable normale multipliée par une constante reste normale.

Théorème 6.4 (méthode delta)**.** Dans le cadre du théorème 5.4, soit $f : \mathbb{R} \to \mathbb{R}$ de classe $\mathcal{C}^1$ avec $f'(\mu) \neq 0$. Alors

$$\frac{\sqrt{n}\,(f(\overline{X}_n) - f(\mu))}{|f'(\mu)|\,\sigma} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1).$$

Autrement dit, $f(\overline{X}_n)$ est approximativement normale, centrée en $f(\mu)$, d'écart-type $|f'(\mu)|\,\sigma/\sqrt{n}$.

Démonstration. Notons $Y_n = \frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma}$, qui converge en loi vers $\mathcal{N}(0,1)$. Par l'égalité des accroissements finis, il existe c_n entre μ et $\overline{X}_n$ avec $f(\overline{X}_n) - f(\mu) = f'(c_n)(\overline{X}_n - \mu)$. Donc

$$\frac{\sqrt{n}\,(f(\overline{X}_n) - f(\mu))}{|f'(\mu)|\sigma} = \pm A_n Y_n, \qquad A_n = \frac{f'(c_n)}{f'(\mu)},$$

le signe étant celui de $f'(\mu)$. Comme $|c_n - \mu| \leq |\overline{X}_n - \mu|$, on a $c_n \xrightarrow[n\to+\infty]{\mathbb{P}} \mu$, et f' est continue : $A_n \xrightarrow[n\to+\infty]{\mathbb{P}} 1$ (lemme 6.2). Le lemme de Slutsky (point 3) conclut, en remarquant que $-Y$ suit la loi $\mathcal{N}(0,1)$ si Y la suit (parité de φ). ■

Partie D — Les sondages, et au-delà

7 La marge d'erreur d'un sondage

Le TCL (sous la forme de Moivre-Laplace) donne

$$\mathbb{P}\Big(|\widehat{p}_n - p| \le 1{,}96\,\frac{\sqrt{p(1-p)}}{\sqrt{n}}\Big) \xrightarrow[n\to+\infty]{} 95\,\%.$$

Mais cette marge dépend de p, justement inconnu. L'idée naturelle est de remplacer p par son estimation $\widehat{p}_n$ dans l'écart-type. Le lemme de Slutsky justifie ce remplacement, puisque $\widehat{p}_n$ est proche de p quand n est grand.

Théorème 7.1 (intervalle de confiance asymptotique)**.** Soit $\widehat{p}_n$ la proportion observée sur n réponses indépendantes de Bernoulli de paramètre $p \in]0,1[$, et $z > 0$. Alors

$$\mathbb{P}\Big(|\widehat{p}_n - p| \le z\sqrt{\frac{\widehat{p}_n(1-\widehat{p}_n)}{n}}\Big) \xrightarrow[n\to+\infty]{} \Phi(z) - \Phi(-z) = 2\Phi(z) - 1.$$

Pour $z = 1{,}96$, la limite vaut 95 %.

Démonstration. Par Moivre-Laplace,

$$Y_n = \frac{\sqrt{n}\,(\widehat{p}_n - p)}{\sqrt{p(1-p)}} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1).$$

Posons $A_n = \sqrt{\dfrac{p(1-p)}{\widehat{p}_n(1-\widehat{p}_n)}}$ si $\widehat{p}_n \notin \{0,1\}$, et $A_n = 1$ sinon. Comme $\widehat{p}_n$ converge en probabilité vers p et que $y \mapsto \sqrt{p(1-p)/(y(1-y))}$ est continue en p, A_n converge en probabilité vers 1 (lemme 6.2). Par Slutsky, $A_n Y_n \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$. Sauf sur l'événement $\{\widehat{p}_n \in \{0,1\}\}$, dont la probabilité $p^n + (1-p)^n$ tend vers 0, l'événement de l'énoncé s'écrit $\{-z \le A_n Y_n \le z\}$, dont la probabilité tend vers $\Phi(z) - \Phi(-z)$ (la convergence de $\mathbb{P}(A_n Y_n < -z)$ vers $\Phi(-z)$ s'obtient en encadrant par $\mathbb{P}(A_n Y_n \le -z)$ et $\mathbb{P}(A_n Y_n \le -z - \delta)$). ∎

Application 7.1 — « 52 % avec une marge de 3 points »

Pour $n = 1\,000$ et $\widehat{p}_n = 0{,}52$, l'intervalle à 95 % est

$$0{,}52 \pm 1{,}96\sqrt{\frac{0{,}52 \times 0{,}48}{1\,000}}, \quad \text{soit} \quad [48{,}9\,\%;\, 55{,}1\,\%].$$

La marge maximale, atteinte pour $\widehat{p}_n = \frac{1}{2}$, vaut $1{,}96 \times \frac{0{,}5}{\sqrt{1\,000}} \approx 3{,}1$ points : c'est la « marge de 3 points » annoncée pour tout sondage de 1 000 personnes. Comparée aux 7,1 points de Bienaymé-Tchebychev, elle est plus de deux fois plus fine : c'est le gain apporté par la connaissance de la *forme* de la loi.

Conséquences. Le candidat à 52 % n'est pas certain d'être majoritaire : l'intervalle contient 50 %. Pour une marge de 1 point, il faudrait $n = (1{,}96 \times 0{,}5/0{,}01)^2 \approx 9\,604$ personnes : diviser la marge par 3 coûte 9 fois plus d'entretiens. Enfin, l'écart entre deux candidats, $\widehat{p}_n - (1-\widehat{p}_n) = 2\widehat{p}_n - 1$, a une marge double : 6,2 points.

Remarque 7.2 (ce que signifie « 95 % »)**.** Ce n'est pas « p a 95 % de chances d'être dans l'intervalle » : p n'est pas aléatoire, c'est l'intervalle qui l'est. Le sens est : la *méthode* produit un intervalle qui contient la vraie valeur pour environ 95 % des échantillons possibles. Un sondage sur vingt, en moyenne, se trompe de plus que sa marge, sans faute de l'institut.

7.1 Pourquoi la taille de la population n'intervient pas

Un institut n'interroge jamais deux fois la même personne : le tirage est *sans remise*, et les X_i ne sont plus exactement indépendantes. Calculons l'effet exact sur la variance.

Proposition 7.3 (variance d'un tirage sans remise)**.** Une population de N personnes contient K « oui », et $p = K/N$. On tire sans remise $n \leq N$ personnes ; soit S le nombre de « oui » obtenus. Alors $\mathbb{E}[S] = np$ et

$$\mathbb{V}(S) = np(1-p)\,\frac{N-n}{N-1}.$$

Démonstration. Soit X_i l'indicatrice de « la i-ème personne tirée répond oui ». Par symétrie, chaque personne de la population a la même probabilité d'être la i-ème tirée, donc $\mathbb{P}(X_i = 1) = K/N = p$; et pour $i \neq j$, $\mathbb{P}(X_i = X_j = 1) = \frac{K(K-1)}{N(N-1)}$. D'où $\mathbb{E}[S] = np$. En développant le carré comme dans la proposition 1.4, mais sans pouvoir annuler les termes croisés,

$$\mathbb{V}(S) = \sum_i \mathbb{V}(X_i) + \sum_{i \neq j} \mathrm{Cov}(X_i, X_j),$$

où, pour $i \neq j$,

$$\mathrm{Cov}(X_i, X_j) = \frac{K(K-1)}{N(N-1)} - \frac{K^2}{N^2} = \frac{K(K-N)}{N^2(N-1)} = -\frac{p(1-p)}{N-1}.$$

Donc $\mathbb{V}(S) = np(1-p) - n(n-1)\frac{p(1-p)}{N-1} = np(1-p)\left(1 - \frac{n-1}{N-1}\right) = np(1-p)\frac{N-n}{N-1}$. ∎

Le facteur $\frac{N-n}{N-1}$ est tout l'effet de la population. Pour $N = 49$ millions d'électeurs et $n = 1\,000$, $\sqrt{(N-n)/(N-1)} \approx 0{,}99999$: la marge est inchangée. Elle dépend de la *taille de l'échantillon*, pas de celle de la population : une cuillère de soupe bien mélangée renseigne sur le goût de la soupe, que la marmite soit petite ou grande. (Un TCL pour les tirages sans remise existe, dû à Hájek ; il est admis ici. Il confirme que l'approximation normale reste valable quand n et $N - n$ sont grands.)

Pour aller plus loin

Ce que la marge ne couvre pas. Le théorème suppose un tirage au hasard et des réponses sincères. Les vrais sondages souffrent surtout d'erreurs *systématiques* : personnes injoignables, refus de répondre, échantillons par quotas redressés, électeurs indécis. Ces biais ne diminuent pas quand n augmente ; la marge « $1{,}96\sqrt{p(1-p)/n}$ » ne mesure que l'erreur due au hasard de l'échantillon. On retrouvera exactement la même distinction en physique : erreur aléatoire et erreur systématique.

8 Au-delà des sondages

Application 8.1 — la méthode de Monte-Carlo

Pour calculer $I = \displaystyle\int_0^1 h(x)\,\mathrm{d}x$, avec h continue, on tire $U_1, \ldots, U_n$ indépendantes de loi uniforme sur $[0,1]$ et l'on calcule $\widehat{I}_n = \dfrac{1}{n}\displaystyle\sum_{i=1}^{n} h(U_i)$. On a $\mathbb{E}[h(U_1)] = I$ et $\sigma^2 = \mathbb{V}(h(U_1)) = \displaystyle\int_0^1 h^2 - I^2$; par le TCL, l'erreur $\widehat{I}_n - I$ est approximativement normale d'écart-type $\sigma/\sqrt{n}$. Pour estimer π, on tire des points uniformes dans le carré $[0,1]^2$ et l'on compte la proportion de ceux qui tombent dans le quart de disque : c'est une proportion de paramètre $\pi/4$, et $4\widehat{p}_n$ estime π avec un écart-type $4\sqrt{\frac{\pi}{4}(1-\frac{\pi}{4})}/\sqrt{n} \approx 1{,}64/\sqrt{n}$. Un million de points donnent π à environ $\pm 0{,}003$

(deux écarts-types) : la convergence en $1/\sqrt{n}$ est lente, mais elle ne dépend pas de la dimension, ce qui rend la méthode indispensable pour des intégrales en dimension 100 (physique statistique, finance).

Application 8.2 — le contrôle de qualité

Une machine remplit des paquets de masse nominale 500 g ; les masses ont un écart-type $\sigma = 4$ g. Le contrôleur pèse 25 paquets et calcule la moyenne. Si la machine est bien réglée, $\overline{X}_n$ est approximativement $\mathcal{N}(500, (4/5)^2)$, donc tombe entre 498,4 g et 501,6 g avec une probabilité d'environ 95 % ($\pm 2 \times 0{,}8$ g). Une moyenne de 497 g est donc un signal de dérive : c'est le principe des cartes de contrôle de Shewhart.

Application 8.3 — la marche aléatoire et la diffusion

Une particule fait n pas indépendants de $\pm a$, équiprobables (un grain de pollen bousculé par les molécules d'eau). Sa position S_n a une espérance nulle et un écart-type $a\sqrt{n}$: la distance typique parcourue croît comme la *racine* du nombre de pas, donc du temps. C'est la loi de la diffusion (Einstein, 1905) : une goutte d'encre s'étale en $\sqrt{t}$, et pas en t. Par le TCL, la position est approximativement normale : c'est le profil gaussien d'une tache qui diffuse.

Partie E — Les incertitudes en physique-chimie

9 Le modèle d'une mesure

On mesure une grandeur de valeur vraie x_0. Le résultat d'une mesure est modélisé par

$$X = x_0 + b + E,$$

où b est une **erreur systématique** (un étalonnage faux, une parallaxe toujours dans le même sens), la même à chaque mesure, et E une **erreur aléatoire** d'espérance nulle et d'écart-type σ, qui change d'une mesure à l'autre.

Pourquoi E est-elle normale ? L'erreur aléatoire résulte d'un grand nombre de petites perturbations indépendantes : vibrations, fluctuations de température, temps de réaction de l'opérateur, bruit électronique, lecture entre deux graduations… Si $E = E_1 + E_2 + \cdots + E_m$ avec des E_k indépendantes, centrées, et *aucune ne dominant les autres* (condition de Lindeberg, théorème 5.1), alors E est approximativement normale. Les lois des E_k peuvent être toutes différentes : c'est pourquoi on a démontré le théorème de Lindeberg et pas seulement le cas des variables de même loi. Gauss justifiait la loi qui porte son nom par d'autres arguments ; c'est Laplace qui a vu le rôle de la somme de nombreuses causes.

10 L'incertitude d'une moyenne : d'où vient $s/\sqrt{n}$

On répète la mesure n fois dans les mêmes conditions : $X_1, \dots, X_n$ indépendantes, de même loi, d'espérance $x_0 + b$ et de variance σ^2. On ne connaît pas σ : on l'estime.

Proposition 10.1 (l'écart-type expérimental, et le $n-1$)**.** Pour $n \geq 2$, posons

$$s_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2.$$

Alors $\mathbb{E}[s_n^2] = \sigma^2$. Si de plus $\mathbb{E}[X_1^4] < +\infty$, alors s_n converge en probabilité vers σ.

Démonstration. Notons $m = \mathbb{E}[X_1]$. En développant, $\sum_i (X_i - \overline{X}_n)^2 = \sum_i (X_i - m)^2 - n(\overline{X}_n - m)^2$ (on écrit $X_i - \overline{X}_n = (X_i - m) - (\overline{X}_n - m)$ et l'on utilise $\sum_i (X_i - m) = n(\overline{X}_n - m)$). D'où $\mathbb{E}[\sum_i (X_i - \overline{X}_n)^2] = n\sigma^2 - n \cdot \frac{\sigma^2}{n} = (n-1)\sigma^2$, par le corollaire 1.5. On divise par $n-1$.

Pour la convergence, la loi faible des grands nombres (corollaire 1.7), appliquée aux variables $(X_i - m)^2$, de variance finie car $\mathbb{E}[X_1^4] < +\infty$, montre que $\frac{1}{n}\sum_i (X_i - m)^2$ converge en probabilité vers σ^2. Par ailleurs, $(\overline{X}_n - m)^2$ converge en probabilité vers 0 (lemme 6.2 avec $h(y) = (y-m)^2$). Donc

$$\frac{n-1}{n}\, s_n^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - m)^2 - (\overline{X}_n - m)^2 \xrightarrow[n\to+\infty]{\mathbb{P}} \sigma^2,$$

et s_n converge en probabilité vers σ (lemme 6.2 avec la racine carrée, le facteur $\frac{n}{n-1}$ tendant vers 1). ∎

Le $n-1$ des calculatrices (touche σ_{n-1}) vient de là : la moyenne $\overline{X}_n$ est plus proche des données que la vraie valeur m, ce qui fait légèrement sous-estimer la dispersion si l'on divise par n.

Théorème 10.2 (incertitude-type d'une moyenne)**.** Sous les hypothèses précédentes (avec $\mathbb{E}[X_1^4] < +\infty$),

$$\frac{\overline{X}_n - (x_0 + b)}{s_n/\sqrt{n}} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1).$$

Ainsi $\mathbb{P}(|\overline{X}_n - (x_0+b)| \leq 2\, s_n/\sqrt{n}) \to 2\Phi(2) - 1 \approx 95{,}4\,\%$.

Démonstration. On écrit

$$\frac{\overline{X}_n - (x_0+b)}{s_n/\sqrt{n}} = \frac{\sigma}{s_n} \cdot \frac{\sqrt{n}\,(\overline{X}_n - (x_0+b))}{\sigma}.$$

Le second facteur converge en loi vers $\mathcal{N}(0,1)$ (théorème 5.4), et σ/s_n converge en probabilité vers 1 (proposition 10.1 et lemme 6.2, avec la convention $\sigma/s_n = 1$ si $s_n = 0$, événement de probabilité tendant vers 0). Slutsky conclut. ∎

C'est la justification complète de la règle des travaux pratiques : **on donne le résultat sous la forme** $\bar{x} \pm u$ **avec** $u = s/\sqrt{n}$ (incertitude-type, dite « de type A »), et l'on sait que la vraie valeur (corrigée de l'erreur systématique) est dans $\bar{x} \pm 2u$ dans environ 95 % des cas. Trois remarques :

- u décroît en $1/\sqrt{n}$: passer de 10 à 40 mesures divise l'incertitude par 2 ;
- l'erreur systématique b n'est pas réduite par la moyenne : $\overline{X}_n$ converge vers $x_0 + b$, pas vers x_0. Seul un étalonnage la corrige ;
- pour n petit ($n \leq 10$), le théorème n'est qu'asymptotique : si les mesures sont gaussiennes, la loi exacte de $\frac{\overline{X}_n - m}{s_n/\sqrt{n}}$ est la loi de Student à $n-1$ degrés de liberté (admis), et le facteur 2 devient 2,26 pour $n = 10$ et 2,78 pour $n = 5$.

10.1 L'incertitude d'une seule lecture : d'où vient $a/\sqrt{3}$

Quand on ne fait qu'une mesure, avec un instrument gradué ou à affichage numérique, on ne peut pas estimer σ par la dispersion. On modélise alors l'erreur de lecture par une variable *uniforme* sur $[-a, a]$, où a est la demi-largeur de l'intervalle dans lequel on est sûr de se trouver (une demi-graduation, ou la tolérance du constructeur).

Proposition 10.3 (écart-type d'une loi uniforme)**.** Si U suit la loi uniforme sur $[-a, a]$, alors $\mathbb{E}[U] = 0$ et $\sigma_U = \dfrac{a}{\sqrt{3}}$. Pour un affichage numérique de résolution q (intervalle de largeur q, donc $a = q/2$), $\sigma = \dfrac{q}{\sqrt{12}}$.

Démonstration. $\mathbb{E}[U] = 0$ par symétrie, et $\mathbb{E}[U^2] = \dfrac{1}{2a}\displaystyle\int_{-a}^{a} x^2 \,\mathrm{d}x = \frac{1}{2a}\cdot\frac{2a^3}{3} = \frac{a^2}{3}$. ∎

C'est l'incertitude « de type B » : la formule $u = a/\sqrt{3}$, souvent donnée sans explication, est simplement l'écart-type d'une loi uniforme. On choisit l'écart-type (et non a) pour pouvoir *combiner* cette incertitude avec les autres par la règle de la section suivante, qui ne porte que sur des variances.

11 La propagation des incertitudes : d'où viennent les sommes quadratiques

On calcule une grandeur $G = f(x, y)$ à partir de deux grandeurs mesurées indépendamment, d'incertitudes-types u_x et u_y. La formule des manuels est

$$\boxed{u_G = \sqrt{\left(\frac{\partial f}{\partial x}\right)^2 u_x^2 + \left(\frac{\partial f}{\partial y}\right)^2 u_y^2}}$$

et, pour un produit ou un quotient $G = Cx^\alpha y^\beta$,

$$\frac{u_G}{|G|} = \sqrt{\alpha^2\left(\frac{u_x}{x}\right)^2 + \beta^2\left(\frac{u_y}{y}\right)^2}.$$

Voici d'où elles viennent.

11.1 Le cas linéaire : un calcul exact

Proposition 11.1. Si X et Y sont indépendantes, d'écarts-types u_x et u_y, et $G = aX + bY + c$, alors $\sigma_G = \sqrt{a^2u_x^2 + b^2u_y^2}$.

Démonstration. Proposition 1.4 : $\mathbb{V}(G) = a^2\mathbb{V}(X) + b^2\mathbb{V}(Y)$. ∎

C'est toute la raison des sommes quadratiques : ce sont les *variances* qui s'ajoutent, pas les écarts-types. La somme $|a|u_x + |b|u_y$ est une majoration *certaine* de l'erreur dans le pire des cas (les deux erreurs dans le même sens, à leur maximum) ; la somme quadratique décrit l'erreur *typique*, car deux erreurs indépendantes se compensent souvent en partie. Pour deux incertitudes égales, la somme quadratique vaut $\sqrt{2}\,u$ au lieu de $2u$; pour N incertitudes égales, $\sqrt{N}\,u$ au lieu de Nu.

11.2 Le cas général : linéariser, puis appliquer le TCL

Pour une grandeur qui dépend non linéairement des mesures (le pendule, un dosage), on linéarise f autour des valeurs vraies, ce qui ramène au cas précédent, puis on applique le TCL à la partie linéaire. C'est la méthode delta à deux variables.

Théorème 11.2 (propagation des incertitudes)**.** Soit (X_i) et (Y_i) deux suites de mesures, indépendantes l'une de l'autre, chacune formée de variables indépendantes de même loi : $\mathbb{E}[X_i] = \mu$, $\mathbb{V}(X_i) = \sigma_x^2$, $\mathbb{E}[Y_i] = \nu$, $\mathbb{V}(Y_i) = \sigma_y^2$. Soit $f : \mathbb{R}^2 \to \mathbb{R}$ de classe $\mathcal{C}^1$, et $a = \partial_x f(\mu, \nu)$, $b = \partial_y f(\mu, \nu)$, non tous deux nuls. On pose $\tau^2 = a^2\sigma_x^2 + b^2\sigma_y^2$. Alors

$$\frac{\sqrt{n}\,(f(\overline{X}_n, \overline{Y}_n) - f(\mu, \nu))}{\tau} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

L'écart-type de $f(\overline{X}_n, \overline{Y}_n)$ est donc, asymptotiquement,

$$\sqrt{a^2\,\frac{\sigma_x^2}{n} + b^2\,\frac{\sigma_y^2}{n}} = \sqrt{a^2u_x^2 + b^2u_y^2},$$

où $u_x = \sigma_x/\sqrt{n}$ et $u_y = \sigma_y/\sqrt{n}$ sont les incertitudes-types des moyennes.

Démonstration. La partie linéaire. Les variables $V_i = aX_i + bY_i$ sont indépendantes, de même loi (chaque V_i ne dépend que du couple (X_i, Y_i), et ces couples sont indépendants), d'espérance $a\mu + b\nu$ et de variance τ^2 (proposition 11.1). Par le TCL,

$$Y_n := \frac{\sqrt{n}\,(a(\overline{X}_n - \mu) + b(\overline{Y}_n - \nu))}{\tau} = \frac{\sqrt{n}\,(\overline{V}_n - (a\mu + b\nu))}{\tau} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

Le reste. Appliquons l'égalité des accroissements finis à $t \mapsto f\big((\mu, \nu) + t(\overline{X}_n - \mu, \overline{Y}_n - \nu)\big)$ sur $[0, 1]$: il existe un point C_n du segment d'extrémités (μ, ν) et $(\overline{X}_n, \overline{Y}_n)$ tel que

$$f(\overline{X}_n, \overline{Y}_n) - f(\mu, \nu) = \partial_x f(C_n)(\overline{X}_n - \mu) + \partial_y f(C_n)(\overline{Y}_n - \nu).$$

Donc $\dfrac{\sqrt{n}\,(f(\overline{X}_n, \overline{Y}_n) - f(\mu, \nu))}{\tau} = Y_n + R_n$, avec

$$R_n = (\partial_x f(C_n) - a)\,\frac{\sqrt{n}(\overline{X}_n - \mu)}{\tau} + (\partial_y f(C_n) - b)\,\frac{\sqrt{n}(\overline{Y}_n - \nu)}{\tau}.$$

Comme $\overline{X}_n$ et $\overline{Y}_n$ convergent en probabilité vers μ et ν, la distance de C_n à (μ, ν), majorée par $|\overline{X}_n - \mu| + |\overline{Y}_n - \nu|$, tend vers 0 en probabilité ; par continuité des dérivées partielles (preuve identique au lemme 6.2), $\partial_x f(C_n) - a$ et $\partial_y f(C_n) - b$ tendent vers 0 en probabilité. Par ailleurs, Bienaymé-Tchebychev donne

$$\mathbb{P}(|\sqrt{n}\,(\overline{X}_n - \mu)| > K) \le \frac{\sigma_x^2}{K^2},$$

et de même pour $\overline{Y}_n$: ces facteurs sont bornés en probabilité. Le produit d'un facteur qui tend vers 0 en probabilité par un facteur borné en probabilité tend vers 0 en probabilité (même argument qu'au point 3 du lemme 6.3). Donc R_n tend vers 0 en probabilité, et le point 2 de Slutsky conclut. ■

Corollaire 11.3 (produits et quotients : incertitudes relatives)**.** Si $f(x, y) = Cx^\alpha y^\beta$ avec $\mu, \nu > 0$, alors

$$\frac{\tau}{|f(\mu, \nu)|} = \sqrt{\alpha^2\,\frac{\sigma_x^2}{\mu^2} + \beta^2\,\frac{\sigma_y^2}{\nu^2}}\ :$$

les incertitudes relatives s'ajoutent quadratiquement, pondérées par les exposants.

Démonstration. $\partial_x f = \alpha f/x$ et $\partial_y f = \beta f/y$; on divise τ^2 par $f(\mu,\nu)^2$. ∎

Application 11.1 — la mesure de g au pendule

Un pendule simple de longueur L a pour période $T = 2\pi\sqrt{L/g}$, d'où $g = 4\pi^2 L/T^2$. On mesure $L = 1{,}000$ m avec $u_L = 0{,}002$ m, et $T = 2{,}006$ s avec $u_T = 0{,}005$ s (moyenne de plusieurs mesures). On obtient $g \approx 9{,}811\ \mathrm{m\cdot s^{-2}}$ et, par le corollaire 11.3 ($\alpha = 1$, $\beta = -2$),

$$\frac{u_g}{g} = \sqrt{\Big(\frac{u_L}{L}\Big)^2 + 4\Big(\frac{u_T}{T}\Big)^2} = \sqrt{0{,}002^2 + 0{,}004\,99^2} \approx 0{,}005\,4,$$

soit $u_g \approx 0{,}05\ \mathrm{m\cdot s^{-2}}$: $g = (9{,}81 \pm 0{,}05)\ \mathrm{m\cdot s^{-2}}$. L'addition des incertitudes relatives donnerait 0,007 (soit ±0,07), une borne de pire cas. Le facteur 2 devant u_T/T montre que la période doit être mesurée plus soigneusement que la longueur : c'est elle qui domine le bilan.

Application 11.2 — un dosage

Lors d'un titrage, la concentration est $C_A = C_B V_B / V_A$. Avec $C_B = 0{,}100$ mol/L ($u = 0{,}000\,5$), $V_B = 12{,}45$ mL ($u = 0{,}05$) et $V_A = 10{,}00$ mL ($u = 0{,}02$), on trouve $C_A = 0{,}124\,5$ mol/L et une incertitude relative $\sqrt{0{,}005^2 + 0{,}004\,0^2 + 0{,}002^2} \approx 0{,}006\,7$, soit $C_A = (0{,}124\,5 \pm 0{,}000\,8)$ mol/L. (Le théorème a été démontré pour deux grandeurs ; la preuve est identique pour trois.)

Remarque 11.4 (grandeurs corrélées)**.** Si X et Y ne sont pas indépendantes, la proposition 1.4 donne $\mathbb{V}(aX + bY) = a^2\mathbb{V}(X) + b^2\mathbb{V}(Y) + 2ab\,\mathrm{Cov}(X,Y)$: il faut ajouter un terme de covariance. C'est le cas si les deux grandeurs sont mesurées avec le même instrument mal étalonné.

12 Les comptages : d'où vient $\sqrt{N}$

En physique nucléaire, en spectroscopie ou en astronomie, on compte des événements (désintégrations, photons) pendant une durée fixée, et l'on donne le résultat sous la forme $N \pm \sqrt{N}$. Pourquoi ?

Définition 12.1 (loi de Poisson)**.** N suit la loi de Poisson de paramètre $\lambda > 0$ si $\mathbb{P}(N = k) = e^{-\lambda}\frac{\lambda^k}{k!}$ pour $k \in \mathbb{N}$. C'est la loi du nombre d'événements rares et indépendants survenant dans un intervalle de temps, par exemple le nombre de noyaux qui se désintègrent parmi un très grand nombre.

Proposition 12.2. Si $N \sim \mathcal{P}(\lambda)$, alors $\mathbb{E}[N] = \mathbb{V}(N) = \lambda$. Si $N_1 \sim \mathcal{P}(\lambda_1)$ et $N_2 \sim \mathcal{P}(\lambda_2)$ sont indépendantes, $N_1 + N_2 \sim \mathcal{P}(\lambda_1 + \lambda_2)$.

Démonstration.

$$\mathbb{E}[N] = \sum_{k\geq 1} k\, e^{-\lambda}\frac{\lambda^k}{k!} = \lambda \sum_{k\geq 1} e^{-\lambda}\frac{\lambda^{k-1}}{(k-1)!} = \lambda,$$

et de même $\mathbb{E}[N(N-1)] = \lambda^2$, d'où $\mathbb{V}(N) = \mathbb{E}[N(N-1)] + \mathbb{E}[N] - \mathbb{E}[N]^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$. Pour la somme,

$$\mathbb{P}(N_1 + N_2 = k) = \sum_{j=0}^{k} e^{-\lambda_1}\frac{\lambda_1^j}{j!}\, e^{-\lambda_2}\frac{\lambda_2^{k-j}}{(k-j)!} = \frac{e^{-(\lambda_1+\lambda_2)}}{k!}\sum_{j=0}^{k}\binom{k}{j}\lambda_1^j\lambda_2^{k-j} = e^{-(\lambda_1+\lambda_2)}\frac{(\lambda_1+\lambda_2)^k}{k!},$$

par la formule du binôme. ∎

Corollaire 12.3 (approximation normale d'un comptage)**.** Si $N_\lambda \sim \mathcal{P}(\lambda)$, alors, quand λ tend vers $+\infty$ en prenant des valeurs entières,

$$\frac{N_\lambda - \lambda}{\sqrt{\lambda}} \text{ converge en loi vers } \mathcal{N}(0,1).$$

Démonstration. Pour $\lambda = n$ entier, N_n a même loi que $X_1 + \cdots + X_n$ avec des X_i indépendantes de loi $\mathcal{P}(1)$ (proposition 12.2, par récurrence), d'espérance et de variance 1 : c'est le théorème 5.4. ■

L'écart-type d'un comptage est donc la *racine de sa moyenne* ; on l'estime par la racine du nombre observé, d'où « $N \pm \sqrt{N}$ ». L'incertitude relative vaut $1/\sqrt{N}$: 400 coups donnent une précision de 5 %, et il faut 10 000 coups pour atteindre 1 %. C'est pourquoi les expériences de physique des particules accumulent des données pendant des années.

13 Ce que le TCL ne dit pas

— **Les erreurs systématiques.** Elles ne sont ni aléatoires ni réduites par la répétition ; on les estime séparément (type B) et on les combine aux autres par la somme quadratique, en les traitant comme des variables aléatoires dont on ignore le signe.

— **Les petits échantillons.** Le théorème est asymptotique ; pour 3 ou 5 mesures, la loi de Student, valable pour des mesures gaussiennes, est plus honnête que le facteur 2.

— **Les non-linéarités fortes.** La formule de propagation est une linéarisation : si l'incertitude n'est pas petite devant l'échelle où f courbe (une grandeur proche de 0 dans un quotient, par exemple), elle devient fausse.

— **Les queues lourdes et les causes dominantes.** Sans variance finie, ou si une perturbation domine les autres (condition de Lindeberg en défaut), il n'y a aucune raison pour que la loi soit normale.

14 Synthèse

Formule rencontrée	**D'où elle vient**	**Résultat du document**
$\sigma/\sqrt{n}$ pour une moyenne	les variances s'ajoutent	proposition 1.4, corollaire 1.5
« 95 % entre $\pm 2\sigma$ »	la moyenne est presque normale	théorème 5.4 (Lindeberg)
marge $1{,}96\sqrt{\hat{p}(1-\hat{p})/n}$	TCL et Slutsky	théorème 7.1
s avec $n-1$, puis $s/\sqrt{n}$	estimation sans biais de σ^2	proposition 10.1, théorème 10.2
$a/\sqrt{3}$, $q/\sqrt{12}$	écart-type d'une loi uniforme	proposition 10.3
$\sqrt{u_1^2+u_2^2}$, $\sqrt{\sum(\partial_i f)^2 u_i^2}$	linéarisation, variances qui s'ajoutent	proposition 11.1, théorème 11.2
$N \pm \sqrt{N}$	variance d'une loi de Poisson	proposition 12.2
distance en $\sqrt{t}$ (diffusion)	marche aléatoire	proposition 1.4

15 Exercices

Exercice 1 (taille d'un sondage)**.** Combien de personnes faut-il interroger pour garantir, quelle que soit p, une marge de 2 points à 95 % ? Et à 99 % ($\Phi(2{,}576) \approx 0{,}995$) ?

Correction. Il faut $1{,}96 \times \frac{0{,}5}{\sqrt{n}} \leq 0{,}02$, soit

$$n \geq (1{,}96 \times 25)^2 = 2\,401.$$

À 99 %, il faut $n \geq (2{,}576 \times 25)^2 \approx 4\,148$.

Exercice 2 (le dé est-il pipé ?)**.** On lance un dé 6 000 fois et l'on obtient 1 100 six. Si le dé est équilibré, quelle est approximativement la probabilité d'obtenir au moins 1 100 six ? Conclure.

Correction. Sous l'hypothèse d'équilibre, $S \sim \mathcal{B}(6\,000, \frac{1}{6})$, donc $\mathbb{E}[S] = 1\,000$ et

$$\sigma = \sqrt{6\,000 \times \tfrac{1}{6} \times \tfrac{5}{6}} \approx 28{,}9.$$

L'écart 100 représente 3,46 écarts-types. Par Moivre-Laplace, la probabilité vaut environ

$$1 - \Phi(3{,}46) \approx 0{,}000\,3.$$

Un tel excès est très improbable avec un dé équilibré : on conclut que le dé favorise le six.

Exercice 3 (l'erreur ne diminue pas toujours)**.** On mesure n fois une longueur avec une règle dont le zéro est décalé de 0,5 mm. Vers quoi converge la moyenne ? Que dit le théorème 10.2 ?

Correction. Vers $x_0 + 0{,}5$ mm : la loi des grands nombres porte sur l'espérance $x_0 + b$. Le théorème donne un intervalle autour de $x_0 + b$ dont la largeur tend vers 0 : on obtient une valeur très précise… et fausse. Précision et justesse sont deux choses différentes.

Exercice 4 (aire d'un rectangle)**.** On mesure les côtés d'un rectangle : $a = (12{,}0 \pm 0{,}1)$ cm et $b = (5{,}0 \pm 0{,}1)$ cm, mesures indépendantes. Donner l'aire avec son incertitude, puis comparer avec la majoration « pire cas ».

Correction. $S = 60{,}0$ cm^2 et

$$\frac{u_S}{S} = \sqrt{\Big(\frac{0{,}1}{12}\Big)^2 + \Big(\frac{0{,}1}{5}\Big)^2} \approx \sqrt{6{,}9 \cdot 10^{-5} + 4 \cdot 10^{-4}} \approx 0{,}021\,7,$$

soit $u_S \approx 1{,}3$ cm^2. Pire cas : $\frac{0{,}1}{12} + \frac{0{,}1}{5} \approx 0{,}028$, soit 1,7 cm^2. La plus grande incertitude relative (celle de b) domine le bilan.

Exercice 5 (pourquoi $\sqrt{N}$ en comptage)**.** Un compteur Geiger enregistre 2 500 coups en 10 minutes. Donner le taux de comptage par minute avec son incertitude. Combien de temps faut-il compter pour une incertitude relative de 0,5 % ?

Correction. $N = 2\,500 \pm 50$, donc un taux de (250 ± 5) coups par minute (incertitude relative $1/\sqrt{2\,500} = 2\,\%$). Pour 0,5 %, il faut $1/\sqrt{N} = 0{,}005$, soit $N = 40\,000$ coups, c'est-à-dire 160 minutes au même taux.

Exercice 6 (le TCL échoue si une cause domine)**.** Soit X_1 de loi uniforme sur $\{-1, 1\}$ et, pour $i \geq 2$, X_i de loi uniforme sur $\{-2^{-i}, 2^{-i}\}$, toutes indépendantes. Montrer que s_n^2 converge, et que $|S_n/s_n| \geq c > 0$ pour une constante c : S_n/s_n ne peut pas converger vers une loi normale. Quelle hypothèse du théorème de Lindeberg est en défaut ?

Correction. On a $s_n^2 = 1 + \sum_{i=2}^{n} 4^{-i} \le 1 + \dfrac{1}{12}$ (série géométrique), et

$$|X_2 + \cdots + X_n| \le \sum_{i \ge 2} 2^{-i} = \frac{1}{2}.$$

Donc $|S_n| \ge 1 - \frac{1}{2} = \frac{1}{2}$, et

$$\Big|\frac{S_n}{s_n}\Big| \ge \frac{1/2}{\sqrt{13/12}} > 0{,}48.$$

Or une variable normale charge tout intervalle autour de 0 : $\mathbb{P}(|S_n/s_n| \le 0{,}4) = 0$ ne peut pas tendre vers $2\Phi(0{,}4) - 1 > 0$. La condition de Lindeberg est en défaut : X_1 porte presque toute la variance ($\max_i \sigma_i / s_n \ge 1/\sqrt{13/12}$ ne tend pas vers 0).

Exercice 7 (Monte-Carlo)**.** On estime $I = \displaystyle\int_0^1 x^2 \,\mathrm{d}x$ par la méthode de Monte-Carlo avec $n = 10\,000$ points. Calculer l'écart-type de l'estimateur.

Correction.

$$\sigma^2 = \int_0^1 x^4 \,\mathrm{d}x - \Big(\frac{1}{3}\Big)^2 = \frac{1}{5} - \frac{1}{9} = \frac{4}{45},$$

donc $\sigma \approx 0{,}298$ et l'écart-type de l'estimateur vaut $0{,}298/\sqrt{10\,000} \approx 0{,}003$: on obtient $I = \frac{1}{3}$ à environ $\pm 0{,}006$ près (deux écarts-types).

Références

— J. W. Lindeberg, « Eine neue Herleitung des Exponentialgesetzes in der Wahrscheinlichkeitsrechnung », *Mathematische Zeitschrift* 15 (1922) : la méthode de remplacement.

— P. Billingsley, *Probability and Measure*, Wiley : convergence en loi, théorème de Lindeberg-Feller, méthode delta.

— J.-F. Le Gall, *Intégration, probabilités et processus aléatoires* (cours de l'ENS) : fonctions caractéristiques et preuve par le théorème de Lévy.

— BIPM, *Guide pour l'expression de l'incertitude de mesure* (GUM, JCGM 100 :2008) : incertitudes de types A et B, loi de propagation.

— J. R. Taylor, *Incertitudes et analyse des erreurs dans les mesures physiques*, Dunod : sommes quadratiques, justification par la loi normale.